

**ANALISIS OPTIMASI PEMBANGKIT LISTRIK
TENAGA PANAS BUMI (PLTP) DENGAN METODE
SIMULATED ANNEALING (SA), *PARTICLE SWARM
OPTIMIZATION* (PSO), DAN *HYBRID* (PSO-SA)
MELALUI MODEL *SURROGATE* REGRESI
POLINOMIAL**

TUGAS AKHIR

**Karya tulis sebagai salah satu syarat
untuk memperoleh gelar Sarjana dari
Institut Teknologi Bandung**

Oleh

PIRES ANDRIANSYAH

NIM 10222074



**PROGRAM STUDI SARJANA FISIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
INSTITUT TEKNOLOGI BANDUNG
2026**

ABSTRAK

Analisis Optimasi Pembangkit Listrik Tenaga Panas Bumi (PLTP) dengan Metode Simulated Annealing (SA), Particle Swarm Optimization (PSO), dan Hybrid (PSO-SA) melalui Model Surrogate Regresi Polinomial

Oleh
Pires Andriansyah
NIM: 10222074

Pembangkit Listrik Tenaga Panas Bumi (PLTP) merupakan sistem pembangkit listrik bersumber dari energi terbarukan, yaitu panas bumi yang dapat menghasilkan listrik secara kontinu. Namun, performa PLTP sangat dipengaruhi oleh berbagai parameter operasi yang saling berkaitan dan bersifat nonlinear. Penelitian ini bertujuan untuk membangun model yang dapat menangkap karakteristik nonlinear dari data operasional untuk memprediksi daya keluaran bersih. Model yang dibangun merupakan model regresi polinomial yang dibangun dari data operasional PLTP Kamojang. Dilakukan analisis korelasi, seleksi fitur, *preprocessing*, *exploratory data analysis*, dan *hyperparameter tuning*. Dihasilkan model dengan 2 fitur dengan orde polinom 4. Model tersebut menghasilkan R-square sebesar 0.9508, MAE sebesar 0.3372 MW, RMSE sebesar 0.4286, dan MAPE sebesar 0.57% pada data uji. Kemudian model regresi polinomial tersebut digunakan sebagai model *surrogate* untuk mencari solusi optimasi dari fungsi objektif berupa efisiensi eksergi. Proses optimasi dibatasi dengan *trust region* berbasis jarak Mahalanobis untuk menjaga solusi tetap berada di sekitar rentang data operasional. Dalam penelitian ini dilakukan 3 metode optimasi metaheuristik, yaitu *Particle Swarm Optimization* (PSO), *Simulated Annealing* (SA), dan hybrid keduanya (PSO-SA). Hasil optimasi menunjukkan bahwa seluruh variasi PSO secara konsisten menghasilkan daya sebesar 61.4704 MW, sedangkan SA bervariasi menghasilkan daya sebesar 61.4698 MW hingga 61.4703 MW dan variasi hybrid menghasilkan nilai 61.4704 MW. Menunjukkan konsistensi solusi yang tinggi terhadap perubahan algoritma. Dengan eksergi inlet sebesar 119.308 MW, dan daya

optimum 61.4704 MW, menghasilkan efisiensi eksergi sebesar 51.52%, sedangkan kondisi median operasi memberikan efisiensi eksergi sebesar 49.67% menunjukkan bahwa model *surrogate* dan metode optimasi yang digunakan mampu memprediksi dan mengoptimasi daya keluaran dan efisiensi eksergi yang lebih tinggi dibanding kondisi operasi median.

Kata kunci: PLTP Direct Steam, *Surrogate* Model, Polynomial Regression, PSO, SA, Efisiensi Eksergi

ABSTRACT

Optimization Analysis of a Geothermal Power Plant (PLTP) Using Simulated Annealing (SA), Particle Swarm Optimization (PSO), and Hybrid PSO-SA Methods through a Polynomial Regression Surrogate Model

by

Pires Andriansyah

NIM: 10222074

Geothermal Power Plants (GPP) are electricity generation systems powered by renewable geothermal energy that can generate electricity continuously. However, the performance of a PLTP is strongly influenced by various operating parameters that are interrelated and exhibit nonlinear behavior. This study aims to develop a model capable of capturing the nonlinear characteristics of operational data to predict net power output. The developed model is a polynomial regression model built from operational data of the Kamojang Geothermal Power Plant. Correlation analysis, feature selection, preprocessing, exploratory data analysis, and hyperparameter tuning were performed. The resulting model consists of two features with a fourth-degree polynomial. The model achieved an R^2 of 0.9508, an MAE of 0.3372 MW, an RMSE of 0.4286 MW, and a MAPE of 0.57% on the test data. The polynomial regression model was then used as a *surrogate* model to determine the optimal solution for an objective function based on exergy efficiency. The optimization process was constrained using a Mahalanobis-distance-based trust region to ensure that the solutions remained within the range of the operational data. Three metaheuristic optimization methods were employed in this study: Particle Swarm Optimization (PSO), Simulated Annealing (SA), and a hybrid of both methods (PSO-SA). The optimization results show that all PSO variations consistently produced a power output of 61.4704 MW, while the SA variations produced power outputs ranging from 61.4698 MW to 61.4703 MW, and the hybrid variations produced a value of 61.4704 MW. These results indicate a high consistency of the optimal solution across different optimization algorithms. With an inlet exergy of 119.308 MW, the optimum power output of 61.4704 MW

corresponds to an exergy efficiency of 51.52%, while the median operating condition results in an exergy efficiency of 49.67%. These results indicate that the *surrogate* model and optimization methods used in this study are capable of predicting and optimizing power output and exergy efficiency to values higher than those obtained under the median operating condition.

Key words: Direct Steam GPP, Surrogate Model, Polynomial Regression, PSO, SA, Exergy Efficiency.

PENGESAHAN
JUDUL TUGAS AKHIR

Oleh
Pires Andriansyah
NIM: 10222074

Program studi Sarjana Fisika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Institut Teknologi Bandung

Menyetujui

Bandung, 31 Agustus 2026
Dosen Pembimbing,



Prof. Dr. Eng. Alamta Singarimbun, M.Si.
NIP. 196002211990011001

Tim Penguji:

1. Dr.rer.nat. Linus Ampang Pasasa, M.S.
2. Dr.rer.nat. Sparisoma Viridi, S.Si.

*Tugas Akhir ini dipersembahkan untuk
Tuhan, Bangsa, dan Almamater*

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa, karena atas ridha-Nya, penulis senantiasa diberikan nikmat yang luar biasa sehingga penulis dapat merampungkan Tugas Akhir yang berjudul “Analisis Optimasi Pembangkit Listrik Tenaga Panas Bumi (PLTP) dengan Metode Simulated Annealing (SA), Particle Swarm Optimization (PSO), dan Hybrid (PSO-SA) melalui Model *Surrogate* Regresi Polinomial”. Tugas Akhir ini disusun sebagai salah satu syarat untuk memperoleh gelar Sarjana dari Program Studi Sarjana Fisika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Institut Teknologi Bandung.

Penelitian ini dilakukan dengan memanfaatkan data operasional dari salah satu PLTP di Jawa Barat untuk membangun model *surrogate* berbasis regresi polinomial dan mengaplikasikannya dalam metode optimasi untuk menentukan solusi operasional yang optimal. Selama pengerjaan, penulis tidak hanya memperoleh pengalaman, namun banyak sekali penerapan konsep fisika, terutama termodinamika selama penyusunan Tugas Akhir ini. Selain itu, penulis juga termotivasi untuk meningkatkan keterampilan teknis khususnya keterampilan komputasi dan data analisis. Pada penelitian ini, penulis berharap dapat menyebarkan sedikit manfaat baik untuk diri penulis pribadi maupun kemudian bagi dunia riset khususnya dalam lingkup data science.

Penyelesaian Tugas Akhir ini tentu tidak lepas dari peran-peran orang di sekitar penulis, termasuk dukungan, bimbingan, dan bantuan dari berbagai pihak. Karena itu, penulis ingin menyampaikan terimakasih kepada:

1. Prof. Dr. Eng. Alamta Singarimbun, M.Si., selaku dosen pembimbing yang telah memberikan arahan, masukan, dan bimbingan selama proses pelaksanaan penelitian dan penyusunan Tugas Akhir.
2. Dosen dan staf Program Studi Sarjana Fisika ITB, yang telah memberikan ilmu, bantuan, dan dukungan selama penulis menjalani perkuliahan hingga penyelesaian Tugas Akhir.
3. Pihak PLTP yang telah memberikan akses terhadap data operasional yang menjadi dasar penelitian ini. Terutama Pak Qiva Chandra yang telah memberikan saya banyak kesempatan untuk belajar dan melakukan penelitian di PLTP.
4. Keluarga penulis, atas doa, dukungan, kesabaran, dan segala bentuk dukungan finansial maupun moral yang diberikan selama masa perkuliahan hingga penyelesaian Tugas Akhir.

5. Teman-teman penulis yang senantiasa mendampingi penulis selama masa-masa perkuliahan, baik ketika senang, maupun ketika sedang mengalami kesusahan.

Penulis menyadari bahwa Tugas Akhir ini masih memiliki keterbatasan dan masih dapat dikembangkan lebih lanjut. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan untuk penyempurnaan penelitian di masa mendatang. Penulis berharap Tugas Akhir ini dapat memberikan manfaat, baik sebagai bahan pembelajaran maupun sebagai salah satu referensi dalam pengembangan penelitian terkait optimasi dan analisis kinerja Pembangkit Listrik Tenaga Panas Bumi.

Bandung, 31 Agustus 2026

Pires Andriansyah

NIM 10222074

DAFTAR ISI

ABSTRAK	i
ABSTRACT	iii
KATA PENGANTAR	vii
DAFTAR ISI	ix
DAFTAR TABEL	xi
DAFTAR GAMBAR	xii
DAFTAR NOTASI	xiii
DAFTAR SINGKATAN	xiv
I PENDAHULUAN.....	1
I.1 Latar Belakang	1
I.2 Rumusan dan Batasan Masalah.....	2
I.3 Tujuan	4
I.4 Metodologi	4
I.5 Sistematika Penulisan	4
II TINJAUAN PUSTAKA	5
II.1 Sumber Energi Panas Bumi dan PLTP	5
II.1.1 Energi Panas Bumi.....	5
II.1.2 Pembangkit Listrik Tenaga Panas Bumi.....	6
II.2 Analisis Eksergi pada Sistem PLTP.....	9
II.3 Analisis Statistik	11
II.4 Machine Learning dan Model Regresi Polinomial	15
II.5 Metode Optimasi.....	16
II.5.1 Particle Swarm Optimization (PSO).....	17
II.5.2 Simulated Annealing (SA).....	18
II.5.3 Hybrid PSO-SA	19
II.5.4 Metode Optimasi Lainnya	20
III METODOLOGI PENELITIAN	21
III.1 Objek Penelitian	21
III.2 Pemodelan Termodinamika dan Analisis Eksergi pada PLTP Kamojang	21
III.3 Alur Penelitian	23
III.3.1 Data Operasional dan Parameter Termodinamika dari PLTP Kamojang.....	24
III.3.2 Parameter Variabel Optimasi.....	26
III.3.3 Model <i>Surrogate</i> sebagai Fungsi Objektif.....	26
III.3.4 Trust-Region dan Jarak Mahalanobis	28
III.3.5 Implementasi PSO	28

III.3.6 Implementasi SA.....	29
III.3.7 Implementasi Hybrid PSO-SA.....	30
IV HASIL DAN ANALISIS.....	32
IV.1 Model <i>Surrogate</i>	32
IV.1.1 Analisis Korelasi dan Seleksi Fitur.....	32
IV.1.2 Data Preprocessing	35
IV.1.3 Exploratory Data Analysis (EDA).....	37
IV.1.4 Train-Test Split dan Hyperparameter Tuning.....	40
IV.1.5 Model Hasil dan Evaluasi	41
IV.2 Optimasi dengan Metode PSO	45
IV.3 Optimasi dengan Metode SA	49
IV.4 Optimasi dengan Metode Hybrid	52
IV.5 Solusi Optimasi Fungsi Objektif dari Ketiga Algoritma.....	55
V SIMPULAN DAN SARAN.....	60
V.1 Simpulan	60
V.2 Saran.....	60
DAFTAR PUSTAKA	62

DAFTAR TABEL

Tabel III. 1 Karakteristik data operasional.....	24
Tabel III. 2 Contoh data operasional PLTP	25
Tabel III. 3 Parameter algoritma PSO.....	29
Tabel III. 4 Parameter algoritma SA.....	29
Tabel III. 5 Parameter algoritma PSO-SA	29
Tabel IV. 1 Koefisien korelasi untuk setiap parameter terukur	32
Tabel IV. 2 Pengaruh derajat polinom terhadap model	40
Tabel IV. 3 Evaluasi statistik pada model regresi	42
Tabel IV. 4 Hasil optimasi PSO untuk 3 variasi	47
Tabel IV. 5 Hasil optimasi SA untuk 3 variasi.....	49
Tabel IV. 6 Hasil optimasi hybrid untuk 3 variasi	53
Tabel IV. 7 Perbandingan hasil optimasi untuk setiap algoritma	56

DAFTAR GAMBAR

Gambar III. 1 Peta area WKP Kamojang.....	21
Gambar III. 2 Skematik PLTP Kamojang.....	22
Gambar III. 3 Diagram alir alur penelitian	23
Gambar III. 4 Heatmap koefisien korelasi	26
Gambar IV. 1 Heatmap koefisien korelasi untuk 45 parameter terukur di PLTP	35
Gambar IV. 2 Visualisasi boxplot persebaran data variabel prediktif dan variabel target	36
Gambar IV. 3 Visualisasi fluktuasi beban terhadap waktu	37
Gambar IV. 4 Visualisasi persebaran rentang net power.....	38
Gambar IV. 5 Persebaran variabel prediktif terhadap net power	39
Gambar IV. 6 Pengaruh derajat polinom terhadap R-square dan RMSE.....	41
Gambar IV. 7 Persebaran data aktual terhadap prediksi model	43
Gambar IV. 8 Distribusi residual dengan hasil prediksi	44
Gambar IV. 9 Konvergensi dan diversitas partikel dalam optimasi PSO	46
Gambar IV. 10 Diversitas partikel terhadap iterasi.....	46
Gambar IV. 11 Konvergensi dan diversitas untuk setiap variasi	48
Gambar IV. 12 Konvergensi, skema pendinginan, dan tingkat penerimaan solusi lebih buruk untuk ketiga variasi.....	51
Gambar IV. 13 Konvergensi 2 fase PSO-SA	54
Gambar IV. 14 Perbandingan konvergensi untuk 3 metode	55
Gambar IV. 15 Heatmap solusi dan hasil optimasi untuk ketiga metode optimasi	56
Gambar IV. 16 Peta 2D solusi optimasi dengan trust region jarak Mahalanobis	57

DAFTAR NOTASI

Notasi	Arti
$\dot{Q}$	Laju kalor
$\dot{W}$	Laju kerja
$\dot{m}$	Laju alir fluida
v	Kecepatan
g	Percepatan gravitasi
z	Ketinggian
$\dot{\theta}$	Laju entropi
S	Entropi
s	Entropi spesifik
T	Temperatur
h	Entalpi spesifik
$\dot{E}$	Laju eksergi
e	Eksergi
η_{ex}	Efisiensi eksergi
$\dot{W}_{nett}$	Laju kerja bersih
P_{net}	Daya keluaran bersih
P	Tekanan
$\dot{E}_{in}$	Eksergi inlet
$\Delta \dot{E}$	Laju hilang eksergi
$\bar{x}$	Rata-rata
n	Banyak data
x_i	Data ke-i
σ	Standar deviasi
Q_i	Kuartil ke-i
R	Koefisien korelasi Pearson
R^2	Koefisien determinasi
P_{best}	Personal best
G_{best}	Global best
c_1	Koefisien kognitif
c_2	Koefisien sosial
D	Jarak
D_M	Jarak Mahalanobis
w	Bobot inersia
α	Cooling schedule

DAFTAR SINGKATAN

Singkatan	Arti
PLTP	Pembangkit Listrik Tenaga Panas Bumi
GPP	Geothermal Power Plant
GW	Gigawatt
MW	Megawatt
PSO	Particle Swarm Optimization
SA	Simulated Annealing
ORC	Organic Rankine Cycle
GSA	Gravitational Search algoritma
GA	Genetic Algorithm
IQR	Interquartile Range
VIF	Variance Inflation Factor
MAE	Mean Absolute Error
RMSE	Root Mean Squared Error
ML	Machine Learning
AI	Artificial Intelligence
EDA	Exploratory Data Analysis
SI	Swarm Intelligence
MAPE	Mean Absolute Percentage Error
WKP	Wilayah Kerja Panas Bumi
SI	Satuan internasional

BAB I

PENDAHULUAN

I.1 Latar Belakang

Energi panas bumi merupakan salah satu energi terbarukan dengan potensi yang sangat besar, khususnya di Indonesia. Potensi energi panas bumi di Indonesia diperkirakan mencapai 24-29 GW dan merupakan salah satu yang terbesar di dunia. Energi panas bumi ini banyak dimanfaatkan di berbagai sektor, di antaranya untuk pemansan rumah kaca, pengeringan produk pertanian, budidaya jamur, wisata pemandian air panas, dan yang paling masif pemanfaatannya adalah sebagai sumber energi listrik .

Energi panas bumi sebagai salah satu sumber energi terbarukan memiliki karakteristik stabil, tidak bergantung terhadap cuaca, dan berkelanjutan. Namun, pemanfaatan energi panas bumi masih belum optimal, terutama dari segi performa dan efisiensi dari sistem Pembangkit Listrik Tenaga Panas Bumi (PLTP) yang bergantung pada jenis reservoir dan kondisi operasi. Sistem PLTP memiliki sistem termodinamika yang kompleks dan nonlinear, karena melibatkan berbagai parameter seperti konsentrasi uap, laju alir fluida, temperatur, tekanan di setiap komponen, dan pengaruh lingkungan yang berimplikasi pada besarnya daya keluaran juga efisiensi dari PLTP itu sendiri. Berbagai penelitian terdahulu membahas analisis dan optimasi eksergi PLTP menggunakan berbagai pendekatan termodinamika dan metode optimasi, salah satunya adalah dengan analisis eksergi dan metode optimasi komputasi metaheuristik untuk menemukan besaran parameter yang tepat untuk kinerja sistem yang optimal (Pambudi, 2018; Pambudi & Ulfa, 2024).

Berbagai penelitian telah dilakukan untuk melihat berbagai parameter yang dapat membuat sistem PLTP bekerja secara optimal. Gürçan Çetin & Ali Keçebas (2021) melakukan optimasi pada PLTP SINEM yang beroperasi di Aydin, Turki. Menganalisis optimasi sistem PLTP dengan metode *Simulated Annealing* (SA) pada PLTP berjenis *Organic Rankine Cycle* (ORC) dan membandingkan hasilnya dengan metode *Gravitational Search Algorithm* (GSA) dan analisis eksergi termodinamika. Bayu Rudianto, dkk (2023) mengaplikasikan metode *Genetic Algorithm* (GA) untuk mengoptimasi PLTP berjenis *direct steam* di Kamojang, Jawa Barat. Analisis eksergi juga dilakukan untuk melihat komponen dengan

irreversibilitas terbesar pada sistem PLTP Kamojang. Berdasarkan riset tersebut, metode optimasi seperti PSO dan SA dapat menentukan kondisi operasi yang lebih optimal dibandingkan pendekatan konvensional, karena sistem energi memiliki banyak batasan fisik dan hubungan nonlinear. Pengujian metode berbeda memungkinkan hasil yang berbeda pula. Karena itu, pada penelitian ini dilakukan uji optimasi pada sistem PLTP dengan metode metaheuristik lain, yaitu *Particle Swarm Optimization* (PSO) yang dikenal sebagai metode optimasi berbasis populasi yang memiliki mekanisme pencarian sederhana dengan kemampuan konvergensi yang cepat pada permasalahan kontinu dan *Simulated Annealing* (SA) yang merupakan metode pencarian solusi tunggal. Kemudian dibandingkan juga ketika kedua metode optimasi tersebut dihibridisasi, dengan PSO sebagai global search dan SA sebagai local search. Penerapan metode PSO, SA, dan hybrid pada optimasi PLTP berbasis analisis eksergi, khususnya pada sistem direct steam seperti di Kamojang, masih terbatas.

I.2 Rumusan dan Batasan Masalah

Pembangkit Listrik Tenaga Panas Bumi merupakan salah satu bentuk pemanfaatan energi terbarukan yang sangat menjanjikan karena memiliki potensi energi yang besar dan *sustainable*. Namun, dalam praktiknya, pemanfaatan energi panas bumi melalui PLTP masih menghadapi berbagai keterbatasan, terutama pada sisi efisiensi sistem, sehingga daya listrik yang dihasilkan belum sepenuhnya dimanfaatkan secara optimal mengingat potensi sumber energi yang tersedia sangat besar.

Keterbatasan efisiensi tersebut disebabkan oleh karakteristik sistem PLTP yang kompleks dan memiliki berbagai batasan fisik, seperti keterbatasan temperatur dan tekanan uap, kualitas uap, serta kondisi lingkungan yang mempengaruhi kinerja komponen-komponen pada pembangkit. Akibatnya, peningkatan performa PLTP tidak dapat dilakukan secara sederhana hanya dengan menambah sumber energi, melainkan memerlukan pengaturan kondisi operasi sistem secara tepat.

Meskipun sistem PLTP memiliki batasan fisik yang tidak dapat diubah, sistem ini tetap memiliki sejumlah parameter operasi yang dapat dikendalikan, seperti temperatur dan tekanan inlet turbin, laju alir fluida, dan kondisi kerja kondensor. Pengaturan parameter-parameter tersebut berpotensi meningkatkan daya keluaran dan efisiensi sistem apabila ditentukan pada kondisi yang optimum.

Oleh karena itu, diperlukan suatu pendekatan yang mampu menentukan kombinasi parameter operasi yang paling sesuai dengan karakteristik sistem dan batasan fisik yang ada. Pendekatan optimasi menjadi penting untuk memastikan

bahwa PLTP dapat beroperasi pada kondisi yang memberikan performa terbaik.

Pada penelitian ini, dilakukan kajian pada sistem PLTP berjenis *direct steam* dengan data operasional dari PLTP Kamojang. Model termodinamika yang digunakan dalam kondisi tunak (*steady-state*) sehingga tidak membahas fenomena transien, seperti proses *start-up* dan *shutdown*. Penelitian ini membangun model *surrogate* berbasis regresi polinomial sebagai fungsi objektif. Kemudian membahas analisis eksergi dan optimasi menggunakan metode PSO, SA, dan hybrid untuk melihat bagaimana respons ketiga metode tersebut terhadap model *surrogate*.

I.3 Tujuan

Penelitian ini bertujuan untuk membangun model *surrogate* berbasis regresi polinomial berdasarkan data operasional PLTP Kamojang untuk merepresentasikan hubungan nonlinear antara parameter operasi terpilih dengan data bersih keluaran. Kemudian ditentukan kondisi operasi optimum dan efisiensi eksergi PLTP melalui optimasi metaheuristik PSO, SA, dan hybrid.

I.4 Metodologi

Penelitian ini menggunakan metodologi eksperimen numerik dengan membangun model termodinamika pada PLTP, mensimulasikan sistem, dan menjalankan optimasi PSO, SA, dan hybrid. Model dibangun berdasarkan data historis operasi selama 3 bulan. Penelitian ini didukung dengan studi pustaka yang berkaitan dengan termodinamika pada sistem PLTP dan metode optimasinya.

I.5 Sistematika Penulisan

Setelah bagian Pendahuluan pada Bab I ini, dilanjutkan ke Bab II yang berisi tinjauan pustaka terkait teori dan hasil penelitian terdahulu yang relevan terhadap topik penelitian. Membahas terkait konsep energi panas bumi, sistem PLTP, ulasan termodinamika dan analisis eksergi, metode optimasi, serta ulasan terkait penggunaan *Particle Swarm Optimization* dan *Simulated Annealing*.

Bab III membahas metodologi yang digunakan pada penelitian secara bertahap, dimulai dari pemodelan termodinamika sistem, analisis energi dan eksergi, penentuan variabel optimasi, penentuan fungsi objektif dan batasannya, dan kemudian penggunaan metode optimasi PSO, SA, dan hybrid.

Bab IV menyajikan hasil model *surrogate* dan optimasi sistem PLTP beserta nilai parameter-parameternya selama proses iterasi menemukan solusi optimum dengan metode PSO, SA, dan hybrid, membahas perbandingan performa sistem sebelum dan sesudah optimasi, serta analisis hasil yang diperoleh berdasarkan prinsip algoritma dan termodinamika.

Bab V berisi kesimpulan yang diperoleh mengenai penelitian secara keseluruhan serta saran untuk penelitian dan pengembangan terkait optimasi dan pengoperasian PLTP.

BAB II

TINJAUAN PUSTAKA

II.1 Sumber Energi Panas Bumi dan PLTP

II.1.1 Energi Panas Bumi

Secara hidrotermal, sistem panas bumi dapat dibedakan berdasarkan jenis fluida produksi dan kandungan fluida utamanya. Sistem satu fasa merupakan sistem yang didominasi oleh air panas dengan temperatur relatif rendah hingga menengah, umumnya berkisar antara 90°C hingga 180°C. Sementara itu, sistem dua fasa terdiri atas campuran uap dan air, yang selanjutnya dibedakan menjadi sistem dominasi uap dan sistem dominasi air. Sistem dominasi uap dicirikan oleh reservoir yang rongga-rongganya sebagian besar terisi uap panas, sehingga sumur produksinya menghasilkan uap kering atau uap basah. Contoh lapangan panas bumi dengan sistem dominasi uap di Indonesia adalah Kamojang dan Darajat, yang memiliki temperatur reservoir berkisar antara 230°C hingga 246°C. Sebaliknya, sistem dominasi air menghasilkan fluida dua fasa berupa campuran uap dan air panas, dengan temperatur reservoir yang lebih bervariasi, umumnya berada pada rentang 200°C hingga 347°C. Lapangan panas bumi seperti Dieng, Gunung Salak, Patuha, Bali, dan Karaha termasuk ke dalam kategori sistem dominasi air.

Selain diklasifikasikan berdasarkan jenis fluida, sistem panas bumi juga dapat dikelompokkan berdasarkan tingkat entalpi fluida reservoir, yaitu sistem entalpi rendah, entalpi sedang, dan entalpi tinggi (Lee, 2000). Sistem entalpi rendah umumnya dimanfaatkan untuk keperluan non-listrik seperti pemanasan ruang, pengeringan hasil pertanian, budidaya perikanan, dan pemandian air panas. Sistem entalpi sedang hingga tinggi, di sisi lain, memiliki potensi besar untuk dimanfaatkan sebagai sumber energi pembangkit listrik karena temperatur dan kandungan energi termalnya cukup untuk menggerakkan turbin secara ekonomis.

Pemanfaatan energi panas bumi untuk pembangkitan listrik dilakukan dengan memanfaatkan uap atau air panas dari reservoir untuk menggerakkan turbin yang terhubung dengan generator. Bergantung pada karakteristik fluida dan temperatur reservoir, pembangkit listrik tenaga panas bumi dapat beroperasi dalam beberapa konfigurasi siklus, seperti siklus uap kering (*dry steam*), siklus flash tunggal atau ganda (*single* dan *double flash*), serta siklus biner (*binary cycle*) yang menggunakan fluida kerja sekunder. Keunggulan utama energi panas bumi dibandingkan sumber

energi terbarukan lainnya adalah sifatnya yang andal dan berkelanjutan, karena tidak bergantung pada kondisi cuaca dan mampu menyediakan daya secara kontinu sebagai beban dasar. Dengan karakteristik tersebut, energi panas bumi memiliki peran strategis dalam mendukung transisi energi dan pengurangan emisi gas rumah kaca, khususnya di negara-negara yang berada pada jalur cincin api seperti Indonesia yang memiliki potensi panas bumi sangat besar (Nenny & Saptadji).

II.1.2 Pembangkit Listrik Tenaga Panas Bumi

Pengembangan sumber daya panas bumi dimulai dari pemahaman geologi wilayah yang berpotensi mengandung sistem panas bumi. Daerah panas bumi umumnya berasosiasi dengan aktivitas tektonik dan vulkanik, seperti zona subduksi, sesar aktif, dan daerah gunung api.

Tahap berikutnya adalah eksplorasi, yang bertujuan untuk mengidentifikasi keberadaan reservoir, memperkirakan temperatur dan ukuran sumber daya, serta menilai kelayakan teknis dan ekonominya. Program eksplorasi dilakukan secara bertahap dan terintegrasi. Tahap awal biasanya berupa studi literatur dan kompilasi data regional untuk mengidentifikasi indikasi geotermal seperti manifestasi permukaan, sejarah vulkanisme, dan struktur geologi utama. Selanjutnya dilakukan survei udara (*airborne survey*) untuk memetakan anomali termal dan struktur besar secara regional.

Eksplorasi kemudian dilanjutkan dengan survei geologi lapangan untuk memetakan litologi, sesar, rekahan, dan fuma panas bumi di permukaan. Survei hidrologi dilakukan untuk memahami sistem aliran air tanah dan hubungan antara recharge area, reservoir, dan zona discharge. Survei geokimia bertujuan untuk menganalisis komposisi kimia fluida panas bumi dan gas untuk memperkirakan temperatur reservoir melalui metode geotermometri serta mengidentifikasi asal-usul fluida. Sementara itu, survei geofisika seperti pengukuran resistivitas, magnetotellurik, gravitasi, dan seismik digunakan untuk memetakan struktur bawah permukaan, ketebalan batuan penudung, serta zona permeabel yang berpotensi menjadi reservoir.

Semua data hasil survei tersebut kemudian disintesis dan diinterpretasikan secara terpadu untuk membangun model konseptual sistem panas bumi. Model ini menggambarkan hubungan antara sumber panas, jalur aliran fluida, reservoir, dan zona keluaran fluida ke permukaan. Model konseptual menjadi dasar utama dalam menentukan lokasi pengeboran sumur eksplorasi.

Tahap pengeboran merupakan langkah kritis dan paling mahal dalam pengembangan panas bumi. Pengeboran dilakukan untuk membuktikan keberadaan

reservoir, mengukur temperatur dan tekanan sebenarnya, serta menguji produktivitas sumur. Proses pengeboran melibatkan persiapan lokasi, penggunaan rig pengeboran khusus panas bumi, serta penerapan prosedur keselamatan karena risiko temperatur tinggi, tekanan tinggi, dan gas beracun seperti H_2S . Sumur eksplorasi yang berhasil kemudian diuji melalui uji alir (*well testing*) untuk menentukan laju alir massa, karakteristik fluida (uap, air, atau dua fasa), serta stabilitas produksi.

Setelah keberadaan reservoir terkonfirmasi, tahap berikutnya adalah rekayasa reservoir (*reservoir engineering*). Pada tahap ini dilakukan analisis aliran fluida dari reservoir ke sumur menggunakan hukum Darcy dan model aliran satu fasa maupun dua fasa. Lokasi horizon flash di dalam sumur dianalisis untuk memahami di mana air panas mulai berubah menjadi uap. Selain itu, dilakukan pengukuran tekanan dan temperatur, pengukuran laju alir massa secara langsung atau tidak langsung, serta analisis transien tekanan untuk memperkirakan permeabilitas, batas reservoir, dan kapasitas penyimpanan fluida.

Data hasil uji sumur dan produksi awal kemudian digunakan untuk membangun model numerik reservoir. Model ini dikalibrasi dan divalidasi melalui proses history matching, yaitu mencocokkan hasil simulasi dengan data produksi aktual. Model reservoir berfungsi sebagai alat utama untuk meramalkan kinerja jangka panjang reservoir, menentukan jumlah dan lokasi sumur produksi serta sumur reinjeksi, dan merancang strategi produksi yang berkelanjutan agar tekanan reservoir tidak turun terlalu cepat.

Jika reservoir dinilai layak secara teknis dan ekonomis, maka pengembangan lapangan dilanjutkan ke tahap pembangunan fasilitas permukaan dan pembangkit listrik tenaga panas bumi. Fluida panas bumi dari sumur produksi dialirkan melalui sistem pengumpulan (*gathering system*) menuju unit konversi energi, seperti pembangkit siklus uap kering, single flash, double flash, atau binary cycle, tergantung pada karakteristik fluida dan temperatur reservoir. Uap yang dihasilkan digunakan untuk memutar turbin yang terhubung dengan generator untuk menghasilkan listrik. Fluida sisa kemudian dikondensasikan dan biasanya diinjeksi kembali ke dalam reservoir untuk menjaga tekanan dan keberlanjutan sistem.

Proses pemanfaatan panas bumi sebagai PLTP merupakan rangkaian panjang yang dimulai dari identifikasi sumber daya, eksplorasi terpadu, pengeboran dan pengujian sumur, rekayasa reservoir, hingga perancangan dan pengoperasian pembangkit listrik. Secara sederhana, semua tahapan untuk pemanfaatan panas bumi hidrotermal dirangkum melalui diagram alir di bawah ini.

Dalam pengembangan pembangkit listrik tenaga panas bumi, jenis PLTP yang digunakan sangat bergantung pada karakteristik fluida dan temperatur reservoir. Perbedaan utama terletak pada fasa fluida yang diproduksi, tingkat entalpi sumber panas, serta skema konversi energi yang diterapkan. DiPippo (2016) mengklasifikasikan sistem pembangkit listrik tenaga panas bumi ke dalam beberapa tipe utama yang telah digunakan secara komersial maupun masih dalam tahap pengembangan. Secara umum, jenis-jenis PLTP tersebut meliputi:

- **Direct steam power plant (dry steam)**, yaitu sistem yang menggunakan uap panas bumi secara langsung dari sumur produksi untuk memutar turbin tanpa melalui proses flashing atau pemisahan tambahan.

Salah satu contoh penerapan sistem direct steam di Indonesia adalah PLTP Kamojang yang berlokasi di Jawa Barat. Lapangan panas bumi Kamojang merupakan lapangan dominasi uap tertua dan paling berkembang di Indonesia, dengan lima unit pembangkit yang seluruhnya menggunakan skema direct steam. Hingga saat ini, PLTP Kamojang terdiri atas Unit 1 sampai Unit 5 dengan total kapasitas terpasang sekitar 235 MW.

- **Single flash steam power plant**, yaitu sistem yang memanfaatkan fluida panas bumi dominasi air, di mana sebagian fluida diuapkan melalui proses flashing pada satu tingkat tekanan sebelum digunakan untuk menggerakkan turbin.
- **Double flash steam power plant**, yaitu pengembangan dari sistem single flash yang menggunakan dua tahap flashing pada tekanan berbeda untuk meningkatkan fraksi uap dan daya keluaran.
- **Triple flash steam power plant**, yaitu sistem yang menggunakan tiga tahap flashing untuk mengekstraksi energi maksimum dari fluida panas bumi bertemperatur sangat tinggi, meskipun jarang digunakan karena kompleksitasnya.
- **Binary cycle power plant (ORC atau Kalina)**, yaitu sistem yang menggunakan fluida kerja sekunder bertitik didih rendah untuk memanfaatkan panas dari fluida panas bumi melalui penukar panas, sehingga cocok untuk reservoir bertemperatur rendah hingga menengah.
- **Hybrid geothermal power plant**, yaitu sistem yang menggabungkan energi panas bumi dengan sumber energi lain, seperti biomassa atau energi surya, untuk meningkatkan fleksibilitas dan keluaran daya.
- **Advanced geothermal power plant**, yaitu sistem panas bumi generasi lanjut seperti enhanced geothermal systems (EGS) dan sistem superkritis, yang masih berada pada tahap riset dan demonstrasi.

Klasifikasi ini menyesuaikan dengan karakteristik sumber panas bumi yang berbeda-beda. Misalnya, pada lapangan panas bumi dominasi uap seperti Kamojang, tipe pembangkit yang paling relevan adalah direct steam power plant dan variasi sistem flash steam, sedangkan untuk lapangan dominasi air atau bertemperatur menengah hingga rendah lebih sesuai digunakan sistem binary cycle atau combined cycle (Nenny & Saptadji, n.d.).

II.2 Analisis Eksergi pada Sistem PLTP

Analisis kinerja Pembangkit Listrik Tenaga Panas Bumi didasarkan pada prinsip-prinsip termodinamika, khususnya Hukum Pertama dan Hukum Kedua Termodinamika. Hukum Pertama Termodinamika menyatakan bahwa energi bersifat kekal, sehingga energi tidak dapat diciptakan maupun dimusnahkan, melainkan hanya dapat berubah bentuk. Pada sistem PLTP yang beroperasi dalam kondisi tunak dan merupakan sistem terbuka, prinsip ini dinyatakan sebagai

$$\dot{Q} - \dot{W} = - \sum_{i=1}^n \dot{m}_i (h_i + \frac{1}{2} v_i^2 + g z_i) \quad (\text{II.1})$$

dengan $\dot{Q}$ merupakan laju perpindahan kalor, $\dot{W}$ laju kerja, n banyaknya inlet dan outlet, $\dot{m}$ laju alir massa, h entalpi spesifik dari fluida dalam sistem, v kecepatan fluida pada setiap inlet dan outlet, g percepatan gravitasi, dan z merupakan ketinggian yang diukur dari titik referensi. Pada sistem terbuka dan keadaan tunak, berlaku juga hukum konservasi massa, secara matematis dituliskan sebagai

$$\sum_i^n \dot{m} = 0 \quad (\text{II.2})$$

dalam konteks PLTP, persamaan ini digunakan untuk menghitung daya turbin, kerja pompa, serta perpindahan panas pada kondensor dan *heat exchanger*. Analisis berbasis Hukum Pertama memastikan bahwa seluruh aliran energi dalam sistem konservatif.

Namun, meskipun neraca energi terpenuhi, Hukum Pertama tidak memberikan informasi mengenai kualitas energi maupun arah proses konversi energi. Energi panas dari reservoir panas bumi yang besar secara kuantitas tidak serta-merta dapat seluruhnya diubah menjadi energi listrik. Analisis energi tidak mampu menjelaskan mengapa sebagian besar energi tersebut tidak dimanfaatkan secara optimal, karena hukum ini tidak mempertimbangkan irreversibilitas yang selalu muncul dalam proses nyata, seperti gesekan fluida, ekspansi uap yang tidak isentropik, dan perpindahan panas dengan beda temperatur hingga.

Keterbatasan tersebut dijelaskan oleh Hukum Kedua Termodinamika, yang menyatakan bahwa setiap proses nyata selalu disertai dengan pembangkitan entropi. Untuk sistem terbuka dalam kondisi tunak, neraca entropi dirumuskan

sebagai

$$\dot{\theta}_p = \frac{dS}{dt} - \sum_{i=1}^n \dot{m}_i s_i - \int_{T_1}^{T_2} \frac{1}{T} \frac{dQ}{dt} \quad (\text{II.3})$$

dengan $\dot{\theta}_p$ laju produksi entropi akibat irreversibilitas sistem, S entropi, t waktu, dan T untuk temperatur. Untuk menentukan hasil ideal dari perhitungan, terdapat dua syarat kondisi termodinamik yang harus dipenuhi. Pertama, semua proses yang terjadi dalam sistem harus semuanya reversibel yang artinya tidak ada energi yang hilang akibat gesekan, turbulensi, atau sebab lain. Kedua, keadaan fluida yang mengalir di dalam sistem harus dalam keadaan setimbang dengan lingkungan sekitarnya. Hal ini mengakibatkan persamaan (II.3) menjadi

$$-\sum_{i=1}^n \dot{m}_i s_i - \int_{T_1}^{T_2} \frac{1}{T} \frac{dQ}{dt} = 0 \quad (\text{II.4})$$

Demikian, Hukum Kedua telah menunjukkan adanya irreversibilitas dan arah proses. Namun, belum secara langsung mengukur seberapa besar potensi kerja yang hilang akibat irreversibilitas tersebut.

Persamaan (II.1) pada kasus sederhana dalam sistem terbuka dan keadaan tunak dengan mengabaikan energi kinetik dan energi potensial dalam sistem serta terdapat perpindahan kalor yang terjadi di antara sistem dan lingkungan dapat ditulis menjadi

$$\dot{Q}_0 - \dot{W} = \dot{m}(h_2 - h_1) \quad (\text{II.5})$$

dengan menyederhanakan persamaan (II.4) untuk sistem dengan satu inlet dan satu outlet, persamaan menjadi

$$-\dot{m}(s_1 - s_2) - \frac{\dot{Q}_0}{T_0} = 0 \quad (\text{II.6})$$

$\dot{Q}_0$ disubstitusikan ke persamaan (II.5) menghasilkan persamaan

$$\dot{W} = \dot{m}(h_1 - h_2 - T_0(s_1 - s_2)) \quad (\text{II.7})$$

Sehingga, berdasarkan kondisi termodinamik yang harus dipenuhi yaitu fluida yang keluar dari sistem harus dalam keadaan setimbang dengan lingkungan, persamaan di atas menjadi

$$\dot{W} = \dot{m}(h_1 - h_0 - T_0(s_1 - s_0)) \quad (\text{II.8})$$

Didefinisikan eksergi sebagai kerja maksimum yang secara teoritis dapat dihasilkan ketika suatu sistem dibawa menuju kondisi keseimbangan dengan lingkungannya. Eksergi spesifik aliran fluida dinyatakan sebagai

$$e = h - h_0 - T_0(s - s_0) \quad (\text{II.9})$$

dengan h_0 , T_0 , dan s_0 secara berurutan adalah entalpi, temperatur, dan entropi lingkungan. Persamaan ini menunjukkan bahwa nilai eksergi tidak hanya bergantung pada besarnya energi (entalpi), tetapi juga pada tingkat ketidakteraturan sistem yang direpresentasikan oleh entropi. Sehingga dapat didefinisikan pula laju aliran eksergi sebagai

$$\dot{E} = \dot{m}e \quad (\text{II.10})$$

yang digunakan untuk menghitung eksergi masuk dan keluar dari setiap komponen dalam sistem.

Ketika kalor ditransfer dari satu sistem ke sistem lain, terdapat eksergi yang ikut berpindah. Besar nilai eksergi yang ditransfer dari perpindahan kalor adalah

$$E_Q = \left(1 - \frac{T_0}{T}\right) Q \quad (\text{II.11})$$

Faktor di dalam kurung adalah siklus karnot ideal yang bekerja di dalam siklus ideal antara T dan T_0 . Sementara eksergi yang dihasilkan dari perpindahan kerja adalah

$$E_W = W \quad (\text{II.12})$$

Sehingga, dengan mengombinasikan neraca energi dan neraca entropi, neraca eksergi untuk sistem terbuka dapat dituliskan sebagai

$$\Delta \dot{E} = \dot{E}_{in} - \dot{E}_{out} = \dot{E}_Q + \sum_{i=1}^n \dot{m}_i e_i - \dot{E}_W - \sum_{j=1}^k \dot{m}_j e_j \quad (\text{II.13})$$

dengan $\Delta \dot{E}$ selisih eksergi masuk dan keluar disebut juga sebagai *exergy loss* atau *exergy destruction rate* yang mengindikasikan hilangnya eksergi dalam sistem (DiPippo, 2016).

Kinerja keseluruhan dalam sistem PLTP dapat dievaluasi menggunakan efisiensi eksergi, yang didefinisikan sebagai perbandingan antara kerja bersih yang dihasilkan sistem dengan eksergi fluida panas bumi yang masuk ke sistem, yaitu

$$\eta_{ex} = \frac{W_{nett}}{\dot{E}_{in}} \quad (\text{II.14})$$

dengan $\dot{W}_{nett} = \dot{E}_{out} = \dot{E}_{in} - \Delta \dot{E}$ sehingga persamaan di atas dapat menjadi

$$\eta_{ex} = 1 - \frac{\sum \Delta \dot{E}}{\dot{E}_{in}} \quad (\text{II.15})$$

W_{nett} juga dapat dianggap sebagai kerja bersih yang dihasilkan oleh sistem pembangkit, dengan kata lain W_{nett} merupakan P_{nett} atau daya bersih keluaran. Sehingga, efisiensi eksergi dapat dihitung melalui persamaan berikut.

$$\eta_{ex} = \frac{P_{net}}{\dot{E}_{in}} \quad (\text{II.16})$$

II.3 Analisis Statistik

Analisis statistik merupakan pendekatan yang digunakan untuk mengolah, merangkum, dan menginterpretasikan data sehingga karakteristik serta hubungan yang terdapat di dalam data dapat dimengerti secara sistematis. Analisis statistik dapat digunakan untuk menggambarkan karakteristik suatu kelompok data, mengetahui pola penyebaran data, serta mengidentifikasi hubungan antara variabel yang diamati. Dalam penelitian berbasis data, analisis statistik juga dapat digunakan sebagai tahap awal untuk memperoleh informasi mengenai karakteristik data sebelum dilakukan analisis lebih lanjut. Analisis statistik dalam penelitian ini digunakan sebagai tahap awal untuk memahami karakteristik data operasional

PLTP dan menentukan hubungan antarparameter.

Metode statistik yang digunakan dalam penelitian ini di antaranya statistik deskriptif, analisis korelasi Pearson, *Variance Inflation Factor* (VIF), analisis regresi, dan evaluasi model regresi.

Statistik deskriptif merupakan metode statistik yang digunakan untuk meringkas dan menggambarkan karakteristik suatu kumpulan data. Statistik deskriptif tidak digunakan untuk menarik kesimpulan terhadap populasi secara langsung, tetapi memberikan gambaran mengenai data yang diamati melalui ukuran pemusatan dan penyebaran data. Ukuran pemusatan yang umum digunakan meliputi *mean* dan median. Nilai rata-rata suatu variabel dirumuskan sebagai

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad (\text{II.17})$$

dengan merupakan nilai pengamatan ke- i dan n merupakan jumlah pengamatan. Selain ukuran pemusatan, tingkat penyebaran data dapat diketahui melalui simpangan baku (*standard deviation*), yang dirumuskan sebagai

$$\sigma = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (\text{II.18})$$

Nilai simpangan baku menunjukkan seberapa jauh nilai pengamatan tersebar dari nilai rata-ratanya. Semakin besar nilai simpangan baku, semakin besar variasi data terhadap nilai rata-ratanya. Selain itu, nilai minimum dan maksimum dapat digunakan untuk mengetahui rentang nilai yang terdapat dalam suatu data. Ukuran penyebaran data juga dapat ditentukan berdasarkan kuartil. Kuartil digunakan untuk mengetahui bagaimana data tersebar pada bagian bawah, tengah, dan atas distribusi. Berbeda dengan rata-rata dan simpangan baku yang dapat cukup sensitif terhadap nilai ekstrem, kuartil relatif lebih robust terhadap keberadaan pengamatan ekstrem karena didasarkan pada posisi data dalam distribusi. Kuartil terdiri atas kuartil pertama (Q_1), kuartil kedua (Q_2), dan kuartil ketiga (Q_3). Kuartil pertama menunjukkan nilai yang berada pada persentil ke-25, kuartil kedua merupakan median atau persentil ke-50, sedangkan kuartil ketiga menunjukkan nilai pada persentil ke-75. Rentang antara kuartil pertama dan kuartil ketiga disebut Interquartile Range (IQR) dan dirumuskan sebagai

$$IQR = Q_3 - Q_1 \quad (\text{II.19})$$

IQR menunjukkan rentang yang mencakup sekitar 50% data di bagian tengah distribusi. Semakin besar nilai IQR, semakin besar penyebaran data pada bagian tengah distribusi. Selain itu, IQR dapat digunakan untuk mendeteksi outlier dalam distribusi data dengan menentukan batas bawah dan batas atas berdasarkan jarak sebesar k kali dari IQR dari kuartil pertama dan ketiga

$$\text{Batas bawah} = Q_1 - k(IQR)$$

dan

$$\text{Batas atas} = Q_3 + k(IQR) \quad (\text{II.20})$$

Suatu pengamatan dikategorikan sebagai kandidat *outlier* apabila nilainya berada di bawah batas bawah atau di atas batas atas tersebut. Koefisien k bisa bernilai 1 hingga 3 sesuai dengan seberapa besar toleransi yang dapat diterapkan dalam distribusi data.

Korelasi merupakan metode statistik yang digunakan untuk mengetahui hubungan antara dua variabel. Salah satu ukuran korelasi yang umum digunakan untuk variabel numerik adalah koefisien korelasi Pearson. Koefisien ini mengukur arah dan kekuatan hubungan linear antara dua variabel. Koefisien korelasi Pearson dapat dinyatakan sebagai

$$R = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (\text{II.21})$$

Nilai koefisien korelasi berada pada rentang

$$-1 \leq R \leq 1.$$

Nilai positif menunjukkan bahwa kedua variabel memiliki kecenderungan saling berbanding lurus, sedangkan nilai negatif menunjukkan kecenderungan perubahan saling berbanding terbalik. Nilai $|R|$ menunjukkan kekuatan hubungan linear, makin mendekati satu menunjukkan hubungan nilai semakin kuat, sementara semakin mendekati nol hubungan linear yang semakin lemah.

Dalam analisis yang melibatkan banyak variabel, hubungan antarvariabel yang kuat dapat menimbulkan multikolinearitas. Multikolinearitas merupakan kondisi ketika terdapat hubungan linear yang kuat antara dua atau lebih variabel independen dalam suatu model. Kondisi ini dapat menyebabkan informasi yang diberikan oleh beberapa variabel menjadi saling tumpang tindih atau dalam arti lain kedua variabel tersebut secara distribusi data menceritakan hal yang sama dan dapat mempengaruhi kestabilan estimasi parameter khususnya dalam analisis regresi. Parameter statistik yang dapat digunakan untuk mengidentifikasi multikolinearitas adalah *Variance Inflation Factor* (VIF). Untuk variabel ke- j , VIF dirumuskan sebagai

$$VIF_j = \frac{1}{1 - R_j^2} \quad (\text{II.22})$$

dengan R_j^2 merupakan koefisien determinasi dari regresi variabel ke- j terhadap variabel independen lainnya. Nilai VIF menunjukkan seberapa besar varians estimasi koefisien suatu variabel meningkat akibat adanya hubungan linear dengan variabel independen lainnya. Semakin besar nilai VIF, semakin kuat indikasi adanya multikolinearitas. Sebagai pedoman umum, nilai VIF yang mendekati 1 menunjukkan tidak adanya multikolinearitas yang berarti, sedangkan nilai yang

semakin besar menunjukkan tingkat multikolinearitas yang semakin tinggi. Batas yang digunakan dalam interpretasi dapat berbeda bergantung pada konteks dan tujuan analisis.

Analisis prediktif persebaran data dapat didekati dengan metode statistik regresi. Analisis ini bertujuan untuk membuat interpretasi matematis hubungan antarvariabel berdasarkan karakteristik dataset. Dalam regresi variabel respons dinyatakan sebagai y dan variabel prediktor dinyatakan sebagai x . Model regresi yang telah dibuat dapat dievaluasi dengan menentukan nilai dari parameter statistik seperti koefisien determinasi (R^2), *Mean Absolute Error* (MAE), dan *Root Mean Squared Error* (RMSE). Penggunaan setiap metrik memberikan informasi yang berbeda mengenai kinerja model.

Koefisien determinasi (R^2 atau R-square) digunakan untuk mengukur akurasi model regresi terhadap distribusi data aktual. R-square dirumuskan sebagai

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad (\text{II.23})$$

dengan y_i merupakan nilai aktual, $\hat{y}_i$ nilai prediksi model, dan $\bar{y}$ sebagai nilai rata-rata aktual. Nilai yang semakin mendekati 1 menunjukkan bahwa model mampu menjelaskan proporsi variasi target yang semakin besar. Sebaliknya, nilai yang semakin rendah menunjukkan bahwa kemampuan model dalam menjelaskan variasi data semakin terbatas. Nilai tidak secara langsung menunjukkan besarnya kesalahan prediksi, sehingga penggunaannya perlu dilengkapi dengan metrik error.

MAE merupakan ukuran rata-rata nilai absolut selisih antara nilai aktual dan nilai prediksi. Dirumuskan sebagai

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \bar{y}_i| \quad (\text{II.24})$$

Nilai ini menggambarkan rata-rata besar kesalahan prediksi dalam satuan yang sama dengan variabel target. Semakin kecil MAE, semakin dekat hasil prediksi model terhadap nilai aktual secara rata-rata.

Seperti MAE, RMSE memiliki satuan yang sama dengan variabel target. RMSE merupakan akar kuadrat dari rata-rata kuadrat selisih antara nilai aktual dan nilai prediksi

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (\text{II.25})$$

Karena nilai error dikuadratkan sebelum dirata-ratakan, RMSE memberikan bobot lebih besar terhadap kesalahan dengan nilai absolut yang besar. Oleh karena itu, RMSE menghasilkan nilai yang menggambarkan kesalahan prediksi dari model. Semakin kecil nilai RMSE maka semakin kecil juga kesalahan prediksi model. Perbandingan MAE dan RMSE juga dapat memberikan informasi tambahan mengenai distribusi kesalahan. Apabila RMSE jauh lebih besar daripada MAE,

kondisi tersebut dapat mengindikasikan adanya sejumlah observasi dengan error yang relatif besar. Adapun parameter untuk mengukur rata-rata besar kesalahan prediksi dalam bentuk persentase dengan *Mean Absolute Percentage Error* (MAPE) dengan rumus berikut (James dkk., 2017)

$$MAPE(\%) = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|. \quad (II.26)$$

II.4 Machine Learning dan Model Regresi Polinomial

Machine Learning (ML) atau pembelajaran mesin merupakan cabang dari Artificial Intelligence (AI) atau kecerdasan buatan yang dapat mempelajari pola atau hubungan berdasarkan kumpulan data untuk menghasilkan prediksi atau keluaran sesuai dengan yang diinginkan (Aslam dkk., 2025). Secara umum, ML dibedakan menjadi supervised learning, unsupervised learning, dan reinforcement learning. Pada supervised learning, model dilatih berdasarkan pasangan data masukan dan keluaran dari suatu kumpulan data untuk mempelajari fungsi yang dapat memprediksi keluaran dari paket data baru. Salah satu metode yang umum digunakan adalah analisis regresi, pendekatan pelatihan data untuk memodelkan persamaan matematis dengan keluaran suatu variabel (Farnham dkk., n.d.).

Linear regression merupakan metode paling dasar yang dapat digunakan untuk memodelkan hubungan antara variabel input dan output melalui fungsi linear. Dalam persamaan matematis, model ini dituliskan sebagai berikut.

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \epsilon \quad (II.27)$$

Regresi linear memiliki keunggulan pada interpretabilitas antar koefisien yang relatif lebih sederhana, namun bentuk ini memiliki keterbatasan jika digunakan untuk hubungan antar variabel yang bersifat nonlinear.

Model regresi lain yang umum digunakan untuk mengakomodasi sifat antarvariabel yang nonlinear adalah regresi polinomial. Melalui model ini interpretasi hubungan yang lebih kompleks dapat tetap dijelaskan dalam model *whitebox* yang cocok untuk kasus-kasus fisis yang memerlukan hubungan eksplisit antara variabel input dan output. Namun, model regresi polinomial sangat bergantung pada orde polinom yang dapat membuatnya menjadi terlalu kompleks sehingga dapat meningkatkan risiko *overfitting* (Farnham dkk., n.d.). Secara umum persamaannya secara matematis adalah sebagai berikut.

$$y = \beta_0 + \sum_{i=1}^n \beta_i X_i + \sum_{i=1}^n \sum_{j=1}^n B_{ij} X_i X_j + \dots \quad (II.28)$$

Membangun model regresi, diperlukan proses data *preprocessing*, *exploratory data analysis* (EDA), *data splitting*, *hyperparameter tuning*, sebelum akhirnya pembentukan model akhir. Data preprocessing merupakan tahap awal untuk membersihkan data dengan menangani data-data yang hilang, berduplikat,

dan memiliki outlier, hingga standardisasi variabel. Setelah data siap, dilakukan tahap EDA untuk memahami karakteristik data. EDA meliputi analisis statistik seperti mengidentifikasi pola, korelasi, dan kemungkinan anomali pada dataset, kemudian divisualisasi umumnya dengan correlation matrix untuk melihat hubungan antara parameter operasi dengan variabel target. Kemudian dipilih fitur yang paling signifikan berdasarkan koefisien korelasinya. Selanjutnya data dipisahkan menjadi dua bagian dengan dua tujuan, 80% dipilih acak sebagai data training dan 20% sebagai data testing untuk memvalidasi hasil training (Farnham dkk., n.d.). Untuk menentukan konfigurasi model dengan performa prediksi terbaik, dapat dilakukan hyperparameter tuning, dalam kasus model regresi polinomial, hyperparameter tuning ini dapat diterapkan untuk menentukan orde dari persamaan regresi. Proses tuning dapat dilakukan menggunakan metode seperti grid search atau random search dengan memanfaatkan data training dengan cross validation. Hasilnya, model dibangun dengan hasil data training dan hyperparameter terpilih. Terakhir, model dievaluasi dengan metrik performa seperti r-square, Mean Absolute Error (MAE), dan Root Mean Squared Error (RMSE) (James dkk., 2017).

II.5 Metode Optimasi

Kinerja Pembangkit Listrik Tenaga Panas Bumi (PLTP) dipengaruhi oleh berbagai parameter fisis yang saling berhubungan secara nonlinear. Hubungan antar parameter tersebut pada dasarnya tidak dapat dijelaskan melalui persamaan analitik sederhana, sehingga untuk mendapatkan nilai pasti yang mencerminkan kinerja PLTP yang optimal harus didapat berdasarkan simulasi numerik berbasis data operasional. Hal ini menjadi salah satu tantangan dalam mencari parameter optimal yang dapat membuat sistem berjalan dengan optimal.

Analisis eksergi menunjukkan bahwa sistem PLTP memiliki keterbatasan mendasar terkait dengan irreversibilitas yang tidak dapat diabaikan. Oleh karena itu, tujuan optimasi pada PLTP untuk meminimalkan kerusakan eksergi atau memaksimalkan pemanfaatan potensi kerja fluida panas bumi dalam batasan fisik dan operasional yang ada. Fungsi objektif yang digunakan dalam optimasi umumnya melibatkan efisiensi eksergi dengan tetap memperhatikan kendala teknis seperti batas tekanan, temperatur, dan laju alir fluida.

Permasalahan optimasi pada sistem PLTP juga ditandai oleh adanya banyak kendala (*constraints*) dan kemungkinan terbentuknya beberapa solusi lokal (*local optima*). Metode optimasi konvensional berbasis gradien sering kali kurang efektif untuk menangani permasalahan semacam ini karena membutuhkan fungsi objektif yang kontinu dan terdiferensiasi dengan baik. Di sisi lain, karakteristik sistem PLTP

yang kompleks dan tidak linier menuntut pendekatan optimasi yang lebih fleksibel dan adaptif.

Untuk mengatasi permasalahan tersebut, berbagai metode optimasi berbasis komputasi dan metaheuristik telah banyak digunakan dalam studi optimasi sistem energi, termasuk PLTP. Metode metaheuristik memiliki keunggulan dalam mengeksplorasi ruang solusi yang luas, tidak bergantung pada informasi gradien, serta mampu menghindari jebakan solusi optimum lokal. Pendekatan ini memungkinkan pencarian solusi mendekati optimum global dengan efisiensi komputasi yang relatif baik, meskipun fungsi objektif bersifat kompleks dan multidimensi.

Berdasarkan pertimbangan tersebut, penelitian ini mengkaji penerapan metode optimasi berbasis metaheuristik dalam meningkatkan kinerja PLTP, khususnya dengan menjadikan analisis eksergi sebagai dasar evaluasi kinerja sistem.

II.5.1 Particle Swarm Optimization (PSO)

PSO mengadaptasi perilaku sosial hewan seperti kawanan burung dan gerombolan ikan. Dalam PSO, setiap kandidat solusi untuk suatu masalah dianggap sebagai partikel yang memiliki kecepatan yang melintasi ruang masalah, selayaknya burung. PSO bekerja mencari solusi dengan menggabungkan informasi posisi terbaik dan posisi saat ini dengan posisi salah satu partikel dalam kawanan untuk mencari posisi berikutnya. Setelah semua partikel berpindah, berlanjut ke iterasi berikutnya. Kemudian pada akhirnya, kawanan tersebut akan secara bertahap mencapai titik optimum dari fungsi objektifnya.

PSO merupakan algoritma probabilitas yang mulanya diperkenalkan oleh Kennedy dan Eberhart. algoritma ini populer di kalangan peneliti karena secara historis memberikan performa yang tinggi dan aplikatif untuk berbagai bidang. PSO dibentuk dari fondasi algoritma *Swarm Intelligence* (SI) yang memiliki fitur utama perorganisasian diri (*self-organization*). Pengorganisasian diri dalam kawanan ini diinterpretasikan oleh Bonabeau dkk. melalui tiga komponen utama sebagai berikut:

- Terdiri dari umpan balik positif dan negatif, struktur yang sesuai dibentuk dengan umpan balik positif (*positive feedback*), sementara pola kolektif distabilkan oleh umpan balik negatif (*negative feedback*).
- Keseimbangan antara eksplorasi dan eksploitasi. Eksplorasi untuk mencari solusi di area baru, sementara eksploitasi untuk mencari solusi terbaik dari area yang sudah ada.
- Setiap agen mendapatkan informasi dari tetangganya dalam kawanan,

sehingga terjadi interaksi di antaranya yang memungkinkan informasi tersebut tersebar ke seluruh jaringan.

Untuk mendapatkan solusi, PSO melakukan pencarian solusi dengan memperbarui posisi relatif dari satu iterasi ke iterasi berikutnya. Untuk mencapai solusi terbaik, PSO bergerak mencari posisi partikel terbaik untuk dirinya (P_{best}) dan posisi terbaik di koloninya (G_{best}). Untuk masalah maksimalisasi, berlaku persamaan berikut.

$$P_{best}^t = X_{best} \mid f(X_i) = \max[f(X_i^k)] \quad (II.29)$$

Dengan X merupakan vektor posisi, $i = 1, 2, 3, \dots, t$, $k = 1, 2, 3, \dots, N$, dan f merupakan fungsi objektif. Sementara t adalah nomor iterasi saat itu dan N jumlah partikel. Untuk menentukan G_{best} digambarkan melalui persamaan di bawah ini.

$$G_{best}^t = X_{best} \mid f(X_i) = \max[f(X_i^k)] \quad (II.30)$$

Kemudian untuk memperbarui posisi partikel, parameter vektor kecepatan (V) dan vektor posisi (X) diubah untuk setiap partikel pada iterasi $t + 1$.

$$V_i^{t+1} = wV_i^t + c_1r_1(P_{best} - X_i^t) + c_2r_2(G_{best} - X_i^t) \quad (II.31)$$

$$X_i^{t+1} = X_i^t + V_i^{t+1} \quad (II.32)$$

Dengan w adalah bobot inersia yang digunakan untuk menyeimbangkan antara eksploitasi lokal dan eksplorasi global, r_1 & r_2 merupakan vektor acak dalam rentang $[0,1]$ yang terdistribusi seragam, dan c_1 & c_2 yang disebut sebagai koefisien akselerasi adalah konstanta positif (Gad, 2022).

II.5.2 Simulated Annealing (SA)

Simulated Annealing merupakan metode optimasi metaheuristik yang diadaptasi dari fenomena *annealing* (penyepuhan) pada logam. Pada proses penyepuhan, material dipanaskan hingga suhu tinggi lalu didinginkan secara perlahan agar atom-atomnya mencapai susunan kristal yang paling stabil dengan energi minimum.

Pada awal proses, dengan suhu sangat tinggi, mengakibatkan atom-atom dalam material memiliki energi yang cukup untuk melompat ke mana saja. Pada data, hal ini bertujuan untuk menemukan dan mengeksplorasi seluruh area agar tidak terjebak dalam solusi lokal. Kemudian, pada proses pendinginan, seiring berjalannya waktu, energi akan berangsur turun hingga habis. Proses pendinginan ini akan membantu data untuk melakukan eksplorasi menemukan titik optimum sebelum akhirnya mencapai konvergensi atau ketika suhu mendekati nol. Ketika itulah, kemungkinan mencapai minimum global atau solusi yang dicari.

Secara matematis, SA bekerja dengan mengevaluasi perubahan fungsi objektif (E , dalam kasus ini efisiensi eksergi) antara solusi saat ini (s) dengan solusi berikutnya (s_{baru}). Jika solusi baru lebih baik ($\Delta E < 0$), solusi selalu diterima,

karena artinya s_{baru} lebih baik daripada s . Sementara jika solusi baru lebih buruk ($\Delta E > 0$), maka solusi masih dapat diterima dengan probabilitas tertentu berdasarkan kriteria Metropolis:

$$P(terima) = e^{-\frac{\Delta E}{T}} \quad (II.33)$$

Dengan $\Delta E = f(s_{baru}) - f(s)$ adalah perbedaan nilai fungsi objektif dan T adalah parameter suhu saat penentuan solusi tersebut.

Suhu T diturunkan secara bertahap menggunakan *cooling schedule* (jadwal pendinginan),

$$T_{k+1} = \alpha T_k \quad (II.34)$$

dengan $0 < \alpha < 1$, umumnya α berkisar antara 0,8 hingga 0,99, penentuannya didasarkan pada tingkat kompleksitas ruang solusi dari fungsi objektif. Sementara itu, suhu awal (T_0) ditetapkan dengan cukup tinggi agar sistem dapat “melompati” bukit-bukit tinggi di awal pencarian sebelum menemukan minimum global (Delahaye dkk., 2019).

II.5.3 Hybrid PSO-SA

Jika PSO terdiri dari sekumpulan partikel yang bergerak di ruang solusi berdasarkan P_{best} dan G_{best} , algoritma ini cenderung memiliki masalah *premature convergence*. PSO bisa sangat cepat berkumpul di suatu wilayah solusi, tetapi kemudian sulit keluar apabila wilayah tersebut ternyata hanya local optimum. Shieh dkk. (2011) mengolaborasikan kecepatan pencarian solusi PSO dengan karakteristik probabilitas metropolis dari SA untuk mempertahankan kemampuan eksplorasi global. Hasilnya terbukti pengujian 20 fungsi optimasi menghasilkan efisiensi komputasi lebih tinggi, kualitas solusi lebih baik, dan kecepatan konvergensi yang lebih cepat dibandingkan dengan algoritma PSO dan SA sendiri.

Javidrad & Nazari (2017) mengembangkan hybrid PSO-SA yang menggunakan PSO dan SA secara berurutan, dengan PSO memberikan kemampuan eksplorasi yang baik kemudian SA digunakan untuk local search. Mereka secara eksplisit menyebut tujuan hybridisasi tersebut sebagai penggabungan kemampuan eksplorasi PSO dengan kemampuan local search SA. Karena itu, skenario hibridisasi PSO-SA dengan mekanisme ini cocok untuk kasus model *surrogate* regresi polinomial karena ruang pencarian seringkali bergelombang, memiliki banyak *local optima*, dan dibatasi oleh banyak keterbatasan termodinamika.

II.5.4 Metode Optimasi Lainnya

Adapun metode komputasi lain yang seringkali digunakan untuk kasus optimasi, di antaranya Gravitational Search algoritma (GSA), Ant Colony Optimization (ACO),

dan Grey Wolf Optimization (GWO).

GSA didasarkan pada hukum gravitasi dan hukum gerak Newton. Dalam metode ini, solusi kandidat dianggap sebagai objek bermassa yang saling tarik-menarik. Objek dengan "massa" lebih berat (artinya memiliki nilai *fitness* lebih baik) akan memberikan gaya gravitasi yang lebih besar, sehingga menarik objek-objek lain yang lebih ringan ke arahnya. GSA memiliki keunggulan berupa kemampuan eksplorasi yang sangat kuat di awal iterasi karena interaksi antar semua massa. Sementara, kekurangannya adalah beban komputasinya meningkat secara eksponensial seiring bertambahnya jumlah populasi karena setiap massa harus menghitung gaya tarik terhadap seluruh massa lainnya (Rashedi dkk., 2009, 2018).

ACO mengadaptasi perilaku semut dalam mencari jalur terpendek antara sarang dan sumber makanan menggunakan jejak zat kimia yang disebut feromon. Solusi yang lebih baik (jalur lebih pendek) akan dilewati lebih sering, sehingga jejak feromonnya semakin tebal dan menarik semut lain untuk lewat di sana. Metode ini sangat efektif untuk masalah optimasi kombinatorial dan penjadwalan. Sementara itu, ACO memiliki masalah waktu analisis yang cenderung lama untuk mencapai konvergensi dan sangat bergantung pada pengaturan penguapan feromon agar tidak terjebak pada jalur suboptimal (Deng dkk., 2019).

GWO meniru hierarki kepemimpinan dan mekanisme berburu serigala abu-abu di alam liar, yang terbagi menjadi empat tingkatan: Alpha, Beta, Delta, dan Omega. Proses optimasi dipandu oleh tiga serigala terbaik (Alpha, Beta, dan Delta) yang memimpin perburuan (pencarian solusi), sementara serigala lainnya memperbarui posisi mereka di sekitar pemimpin tersebut. Kelebihan metode ini adalah memiliki keseimbangan yang sangat baik antara eksplorasi dan eksploitasi, serta sangat stabil untuk berbagai jenis fungsi objektif. Kekurangannya adalah strukturnya yang hierarkis terkadang membuat variasi solusi menjadi rendah di akhir iterasi (Mirjalili dkk., 2014).


BAB III

METODOLOGI PENELITIAN

III.1 Objek Penelitian


Penelitian ini berbasis data operasional PLTP Kamojang pada kondisi puncak dan lepas puncak. PLTP Kamojang bekerja dengan *dry steam system* atau *direct steam* yang memanfaatkan dominasi uap kering untuk memutar turbin tanpa melalui proses pemisahan uap melalui separator atau pertukaran panas dengan *heat exchanger*. Sehingga, efisiensi termal yang dihasilkan lebih baik daripada jenis PLTP lainnya.

PLTP Kamojang berlokasi di Kecamatan Ibum, Kabupaten Bandung, Jawa Barat. Pembangkit listrik ini menghasilkan daya total sebesar 235 MW dari lima unit berbeda yang mampu memasok lebih dari 250.000 rumah. PLTP Kamojang merupakan salah satu unit PLTP di Wilayah Kerja Panas Bumi (WKP) Kamojang-Darajat. Unit ini aktif beroperasi sejak 2008 dan menghasilkan daya maksimum sebesar 60 MW yang merupakan unit dengan daya terbesar di WKP Kamojang-Darajat. Uap kering untuk operasional pembangkit disuplai dari sumur yang tersebar di wilayah tersebut.



Gambar III. 1 Peta area WKP Kamojang

III.2 Pemodelan Termodinamika dan Analisis Eksergi pada PLTP Kamojang


$$\Delta \dot{E}_{steam\ header} = \dot{E}_1 - \dot{E}_2 \quad (\text{III.1})$$

$$\Delta \dot{E}_{scrubber} = \dot{E}_2 - (\dot{E}_3 + \dot{E}_5 + \dot{E}_7) \quad (\text{III.2})$$

$$\Delta \dot{E}_{rock\ muffler} = \dot{E}_3 - \dot{E}_4 \quad (\text{III.3})$$

$$\Delta \dot{E}_{turbin} = \dot{E}_5 - (\dot{E}_6 + \dot{E}_{W\ turbin}) \quad (\text{III.4})$$

$$\Delta \dot{E}_{main\ condenser} = \dot{E}_{11} + \dot{E}_{13} + \dot{E}_{14} + \dot{E}_6 - (\dot{E}_8 + \dot{E}_{24}) \quad (\text{III.5})$$

$$\Delta \dot{E}_{inter\ condenser} = \dot{E}_{15} + \dot{E}_{25} - (\dot{E}_{14} + \dot{E}_{26}) \quad (\text{III.6})$$

$$\Delta \dot{E}_{ejector} = \dot{E}_7 + \dot{E}_{24} - \dot{E}_{25} \quad (\text{III.7})$$

$$\Delta \dot{E}_{IVRP} = \dot{E}_{15} + \dot{E}_{26} - \dot{E}_{27} \quad (\text{III.8})$$

$$\Delta \dot{E}_{separator} = \dot{E}_{27} - (\dot{E}_{13} + \dot{E}_{28}) \quad (\text{III.9})$$

$$\Delta \dot{E}_{cooling\ tower} = \dot{E}_{10} + \dot{E}_{12} + \dot{E}_{19} + \dot{E}_{28} - \dot{E}_{11} - \dot{E}_{17} - \dot{E}_{29} \quad (\text{III.10})$$

$$\Delta \dot{E}_{ACWP} = \dot{E}_{17} - (\dot{E}_{18} + \dot{E}_{15} + \dot{E}_{16}) \quad (\text{III.11})$$

$$\Delta \dot{E}_{CCWP} = \dot{E}_{20} - (\dot{E}_{21} + \dot{E}_{22} + \dot{E}_{23}) \quad (\text{III.12})$$

$$\Delta \dot{E}_{heat\ exchange} = \dot{E}_{20} + \dot{E}_{21} - \dot{E}_{19} \quad (\text{III.13})$$


$$\Delta \dot{E}_{HWP} = \dot{E}_8 - (\dot{E}_9 + \dot{E}_{10}) \quad (\text{III.14})$$

22

$$\begin{aligned} \Sigma \Delta \dot{E} = & \Delta \dot{E}_{steam\ header} + \Delta \dot{E}_{scrubber} + \Delta \dot{E}_{rock\ muffler} + \Delta \dot{E}_{turbin} + \\ & \Delta \dot{E}_{main\ condenser} + \Delta \dot{E}_{inter\ condenser} + \Delta \dot{E}_{ejector} + \Delta \dot{E}_{LVRP} + \Delta \dot{E}_{separator} + \\ & \Delta \dot{E}_{cooling\ tower} + \Delta \dot{E}_{ACWP} + \Delta \dot{E}_{CCWP} + \Delta \dot{E}_{heat\ exchanger} + \Delta \dot{E}_{HWP} \end{aligned} \quad (III.15)$$

III.3 Alur Penelitian

Penelitian yang dilakukan dalam proses optimasi kinerja sistem PLTP Kamojang berbasis analisis eksergi menggunakan metode komputasi metaheuristik. Penelitian diawali dengan pengumpulan dan pengolahan data operasional PLTP yang meliputi parameter termodinamika utama sistem, di antaranya adalah eksergi dari setiap titik komponen dalam sistem. Data tersebut kemudian digunakan sebagai dasar dalam pemodelan sistem untuk mencari solusi dari fungsi objektif dengan nilai maksimum yang merupakan efisiensi eksergi sistem. Secara sederhana, alur penelitian ditunjukkan dalam diagram alir di bawah ini.



Gambar III. 3 Diagram alir alur penelitian

III.3.1 Data Operasional dan Parameter Termodinamika dari PLTP Kamojang

Data operasional dan parameter termodinamika yang digunakan dalam penelitian ini diperoleh berdasarkan data operasi PLTP Kamojang. Data operasional terdiri dari parameter tekanan P , suhu T , dan laju alir massa $\dot{m}$ di setiap titik komponen dalam sistem PLTP. Data operasional ini digunakan sebagai data yang menjadi basis *training* dan *testing* model regresi polinomial untuk menjadi model *surrogate* untuk proses optimasi. Data yang diperoleh diperiksa dan diolah menyesuaikan dengan kebutuhan penelitian.

Tabel III. 1 Karakteristik data operasional

Karakteristik	Keterangan
Unit pembangkit	PLTP Kamojang
Jenis pembangkit	Direct steam
Sumber data	Operasional perusahaan
Periode	19 Februari 2026-19 Juni
Pengamatan	2026
Interval waktu	1 jam
Jumlah data	2905
Jumlah parameter	45
Variabel target	Net power


Tabel III. 9 Contoh data operasional PLTP

Timestamp	Lingkungan		Sumur-header			Inlet turbin L		Inlet turbin R		Turbin	Outlet Turbin		
	P (bar)	T ($^{\circ}C$)	P (barg)	T ($^{\circ}C$)	$\dot{m}$ (T/h)	T ($^{\circ}C$)	P (barg)	T ($^{\circ}C$)	P (barg)	$\dot{m}$ (T/h)	P (bara)	P (bara)	P (bara)
2026/02/19 00:00:00	0.85	17.5	7.48	182.93	49.55	181.65	10.15	182.45	10.23	430.54	0.16	0.15	0.15
2026/02/19 01:00:00	0.85	17.23	7.48	182.88	49.44	181.69	10.17	182.51	10.25	430.65	0.16	0.15	0.15
2026/02/19 02:00:00	0.85	17.21	7.47	182.77	49.44	181.62	10.14	182.36	10.21	431.19	0.16	0.16	0.15
2026/02/19 03:00:00	0.85	17.57	7.47	182.81	49.50	181.65	10.14	182.39	10.21	431.32	0.16	0.16	0.16
2026/02/19 04:00:00	0.85	17.16	7.48	182.92	49.44	181.75	10.13	182.51	10.20	430.88	0.16	0.15	0.15
2026/02/19 05:00:00	0.85	17.43	7.47	182.92	49.45	181.62	10.14	182.36	10.20	431.24	0.16	0.16	0.15
2026/02/19 06:00:00	0.85	17.52	7.48	182.83	49.50	181.69	10.15	182.43	10.22	431.24	0.16	0.16	0.16
2026/02/19 07:00:00	0.85	17.36	7.47	182.84	49.61	181.84	10.21	182.70	10.30	431.02	0.16	0.16	0.16
2026/02/19 08:00:00	0.85	18.04	7.48	182.87	49.42	181.62	10.09	182.22	10.16	429.35	0.16	0.16	0.16
2026/02/19 09:00:00	0.85	17.96	7.48	182.85	49.55	181.62	10.14	182.43	10.23	429.04	0.16	0.16	0.16
2026/02/19 10:00:00	0.85	18.21	7.47	182.75	49.65	181.62	10.15	182.55	10.25	425.38	0.16	0.16	0.16
2026/02/19 11:00:00	0.85	18.64	7.48	182.78	50.47	181.75	10.18	182.67	10.28	421.88	0.16	0.16	0.16
2026/02/19 12:00:00	0.85	18.63	7.46	182.83	50.63	181.65	10.14	182.52	10.24	421.61	0.16	0.16	0.16
2026/02/19 13:00:00	0.85	18.21	7.47	182.33	49.84	181.62	10.14	182.52	10.24	421.13	0.16	0.16	0.16
2026/02/19 14:00:00	0.85	18.68	7.46	182.68	49.89	181.59	10.14	182.55	10.24	417.88	0.16	0.16	0.16
2026/02/19 15:00:00	0.85	17.66	7.46	182.12	49.76	181.65	10.15	182.55	10.24	416.67	0.15	0.15	0.15
2026/02/19 16:00:00	0.85	17.64	7.47	182.66	49.48	181.69	10.12	182.58	10.22	420.42	0.16	0.15	0.15
2026/02/19 17:00:00	0.85	17.56	7.47	182.62	49.49	181.65	10.14	182.54	10.24	424.46	0.16	0.16	0.16
2026/02/19 18:00:00	0.85	17.34	7.47	182.69	49.44	181.62	10.15	182.51	10.24	428.26	0.16	0.16	0.16
2026/02/19 19:00:00	0.85	16.95	7.46	182.80	49.28	181.72	10.17	182.66	10.27	427.53	0.16	0.16	0.15
2026/02/19 20:00:00	0.85	16.82	7.47	182.87	49.40	181.65	10.14	182.51	10.23	429.84	0.15	0.15	0.15
2026/02/19 21:00:00	0.85	16.91	7.47	182.80	49.33	181.69	10.15	182.45	10.23	430.61	0.16	0.15	0.15
2026/02/19 22:00:00	0.85	17.20	7.46	182.81	49.44	181.69	10.16	182.48	10.25	430.72	0.16	0.16	0.15
2026/02/19 23:00:00	0.85	17.33	7.46	182.79	49.45	181.65	10.15	182.42	10.21	431.57	0.16	0.16	0.16
2026/02/20 00:00:00	0.85	17.54	7.48	182.81	49.34	181.69	10.16	182.45	10.22	432.68	0.16	0.16	0.16
2026/02/19 00:00:00	0.85	17.56	7.48	182.85	49.35	181.65	10.15	182.45	10.23	430.54	0.16	0.15	0.15
2026/02/19 01:00:00	0.85	17.34	7.48	182.93	49.55	181.69	10.17	182.51	10.25	430.65	0.16	0.15	0.15
2026/02/19 02:00:00	0.85	16.95	7.48	182.88	49.44	181.62	10.14	182.36	10.21	431.19	0.16	0.16	0.15

III.3.2 Parameter Variabel Optimasi

Proses optimasi dilakukan dengan menentukan beberapa parameter operasi sistem sebagai variabel keputusan (decision variables) yang mempengaruhi keluaran daya bersih berdasarkan data operasional PLTP Kamojang. Parameter yang dipilih merupakan parameter yang paling berpengaruh terhadap daya bersih yang dihasilkan dengan analisis korelasi dan seleksi fitur.

Analisis korelasi digambarkan melalui *heatmap* untuk melihat parameter-parameter yang memiliki koefisien korelasi Pearson dengan nilai terbaik. Diurutkan parameter-parameter dengan koefisien korelasi tertinggi hingga korelasi terkecil, kemudian dipilih beberapa parameter yang akan menjadi kandidat fitur dalam model.



Gambar III. 4 Heatmap koefisien korelasi

Gambar di atas menunjukkan diagram *heatmap* koefisien korelasi antarvariabel, ditampilkan setidaknya 7 di antara 45 parameter yang ada pada data operasional PLTP. Dilakukan EDA untuk memahami karakteristik data variabel prediktif dan variabel respons.

Untuk menentukan pengaruh variasi parameter variabel pada penelitian ini, dibangun fungsi *surrogate* berbasis pada data operasional dengan model regresi polinomial. Kemudian fungsi *surrogate* tersebut melalui proses optimasi dengan metode PSO, SA, dan Hybrid. Hasil dihitung dan divalidasi ulang menggunakan persamaan-persamaan termodinamika sebelumnya.

III.3.3 Model Surrogate sebagai Fungsi Objektif

Setelah melalui proses seleksi fitur dan EDA, parameter yang telah ditetapkan digunakan sebagai variabel masukan dalam pembentukan model *surrogate*. Model

surrogate merupakan model aproksimasi yang digunakan untuk merepresentasikan hubungan antara variabel masukan dan keluaran suatu sistem berdasarkan data yang tersedia. dalam konteks optimasi berbasis data, model seperti regresi polinomial dapat digunakan sebagai salah satu bentuk *surrogate model* karena mampu merepresentasikan hubungan nonlinear dengan biaya komputasi yang relatif rendah dibandingkan evaluasi langsung terhadap model atau sistem yang kompleks.

Pada penelitian ini, parameter terpilih digunakan sebagai prediktor, sedangkan daya bersih digunakan sebagai variabel target. Hubungan antara parameter operasional dan net power dinyatakan sebagai.

$$P_{net} = f(X_1, X_2, \dots, X_n) \quad (\text{III.16})$$

Dataset kemudian dibagi menjadi 2 bagian, 80% untuk data training, dan 20% untuk data testing. Data *training* digunakan untuk membangun dan menentukan konfigurasi model, sedangkan data *testing* dipertahankan sebagai data yang tidak digunakan selama proses pembentukan model untuk mengevaluasi kemampuan generalisasi model. Pemisahan data seperti ini diperlukan untuk menghindari evaluasi model menggunakan data yang telah digunakan dalam proses pembelajaran.

Model *surrogate* yang digunakan dalam penelitian ini berupa Polynomial Regression. Pemilihan regresi polinomial didasarkan pada kemampuan metode tersebut dalam merepresentasikan hubungan nonlinear antara parameter operasi dan daya keluaran. Variabel yang terpilih kemudian melalui transformasi polinomial untuk menghasilkan fitur berupa pangkat variabel dan interaksi antarvariabel. Transformasi tersebut memungkinkan model merepresentasikan hubungan nonlinear antara parameter operasi dan net power. Untuk suatu variabel prediktor X_i , transformasi polinomial dapat menghasilkan suku X_i^2, X_i^3 , serta suku interaksi $X_i X_j$, bergantung pada orde polinomial yang digunakan. Penentuan orde polinom ditentukan dengan metode hyperparameter tuning. Tingkat kompleksitas transformasi polinomial ditentukan melalui parameter pangkat. Orde polinomial 1 sampai 5 diuji menggunakan metode *5-fold cross-validation*. Setiap kandidat orde dikombinasikan dengan StandardScaler dan model Linear Regression dalam suatu pipeline. Penggunaan pipeline memastikan bahwa transformasi fitur dan standardisasi dilakukan secara konsisten pada setiap proses validasi. Hasilnya dipilih berdasarkan rata-rata validasi r-square yang diperoleh dari *cross-validation* dan RMSE pada data validasi dan perbedaan performa antara data *training* dan

validasi digunakan untuk mengevaluasi kemampuan generalisasi model. Orde polinomial dengan performa validasi terbaik kemudian ditetapkan sebagai konfigurasi model *surrogate*. Pemilihan orde ini sangat menentukan performa dari model, karena jika orde terlalu rendah, model tidak akan mampu menangkap pola nonlinear dari data, semetara jika orde terlalu tinggi dapat menghasilkan model yang terlalu kaku mengikuti pola spesifik pada data training (Andersen dkk., 2023).

Terakhir, model *surrogate* dilatih menggunakan seluruh data training dengan konfigurasi orde yang telah ditetapkan. Model tersebut kemudian digunakan untuk memprediksi net power berdasarkan kombinasi parameter input.

III.3.4 Trust-Region dan Jarak Mahalanobis

Karena model *surrogate* dibangun dari data operasional, maka eksplorasi pencarian solusi optimal perlu dibatasi agar solusi berada pada rentang yang pernah diamati oleh sistem pembangkit. Karena itu, penelitian ini menerapkan *trust region* yang dibatasi dengan jarak Mahalanobis. Jarak Mahalanobis digunakan untuk mengukur seberapa jauh suatu kombinasi parameter optimasi dari pola data historis, dengan mempertimbangkan hubungan antarvariabel. Untuk dua fitur yang digunakan, yaitu laju inlet turbin dan tekanan outlet turbin, jarak Mahalanobis dirumuskan sebagai

$$D_M(x) = \sqrt{(x - \bar{x})^T \Sigma^{-1} (x - \bar{x})}. \quad (\text{III.17})$$

Semakin besar D_M , semakin jauh kandidat solusi dari kondisi operasi yang menjadi dasar pembentukan model (Nino-Ruiz, 2018), dengan x adalah vektor kandidat nilai variabel operasi, $\bar{x}$ adalah matriks rata-rata vektor kandidat nilai variabel operasi, dan Σ^{-1} adalah invers matriks kovarians data operasional. Oleh karena itu, jarak Mahalanobis digunakan sebagai pembatas model *surrogate*. Kandidat solusi hanya dapat digunakan apabila

$$D_M(x) \leq D_{max}. \quad (\text{III.18})$$

dengan demikian, algoritma PSO, SA, maupun hybrid PSO-SA tetap mencari nilai *net power* maksimum, tetapi pencariannya dibatasi pada wilayah yang masih didukung oleh data operasional. Pada penelitian ini, ditetapkan threshold 97% dari $D_M(x)$, sehingga nilai $D_{max} = 2.618$. Pendekatan ini digunakan untuk mengurangi risiko model regresi menghasilkan solusi yang tinggi secara matematis tetapi berada terlalu jauh dari kondisi operasi aktual.

III.3.5 Implementasi PSO

Dalam proses optimasi dengan metode PSO, setiap partikel merepresentasikan satu kandidat solusi yang terdiri dari kombinasi parameter operasi sistem, yaitu tekanan wellhead, tekanan inlet turbin, tekanan kondensor, dan laju alir inlet turbin sebagaimana yang tercantum dalam Tabel III.2. Masing-masing partikel akan dievaluasi dengan analisis eksergi untuk menentukan nilai fungsi objektif yang dicari.

Proses optimasi diawali dengan inisialisasi parameter PSO, di antaranya jumlah partikel (N), jumlah iterasi maksimum, inertia weight (w), cognitive coefficient (c_1), dan social coefficient (c_2). Selanjutnya, posisi awal partikel

Tabel III. 17 Parameter algoritma PSO

Parameter algoritma	Variasi		
	1	2	3
Jumlah partikel (N)	30	80	30
Koefisien kognitif (c_1)	1.5	1.5	1.5
Koefisien sosial (c_2)	1.5	1.5	1.5
Jumlah iterasi	100	100	100
Berat inersia (w)	0.7	0.7	0.95

ditetapkan secara acak dalam rentang batas operasi yang telah ditentukan. Pada setiap iterasi, parameter operasi dari masing-masing partikel digunakan untuk menghitung laju kerusakan eksergi hingga kemudian efisiensi eksergi sistem sebagai fitness value dalam proses optimasi. Parameter awal ditetapkan sebagai berikut.

Nilai fitness dari setiap partikel kemudian dibandingkan untuk menentukan personal best (pbest) dan global best (gbest). Berdasarkan nilai

Tabel III. 43 Parameter algoritma SA

Parameter Variabel	Variasi		
	1	2	3
Suhu awal (T_0)	10	50	10
Koefisien pendinginan (α)	0.995	0.995	0.999
Jumlah iterasi	2000	2000	2000
Jarak tetangga	0.05	0.05	0.05

tersebut, posisi dan kecepatan partikel diperbarui menggunakan persamaan PSO hingga mencapai kondisi konvergen atau iterasi maksimum yang ditentukan.

III.3.6 Implementasi SA

Berbeda dengan algoritma berbasis populasi (PSO), SA bekerja dengan mengeksplorasi lingkungan sekitar dari satu titik solusi. Proses dimulai dengan menetapkan suhu awal (T_0), koefisien pendinginan (α), suhu akhir (T_{akhir}), jumlah iterasi (L) dan menentukan solusi awal (s_0). Solusi awal ini merepresentasikan kombinasi parameter operasional pada kondisi awal. Efisiensi eksergi dari posisi awal ini dihitung sebagai nilai fungsi objektif awal ($f(s_0)$). Pada setiap iterasi di suhu tertentu, sistem akan membangkitkan solusi baru (s_{baru}) secara acak dengan memberikan gangguan kecil (perturbation) pada solusi saat ini (s). Solusi baru tersebut kemudian dievaluasi ke dalam model termodinamika PLTP untuk mendapatkan nilai efisiensi eksergi yang baru $f(s_{baru})$.

Perubahan nilai fungsi objektif (ΔE) dihitung melalui selisih antara efisiensi eksergi baru dan lama. Jika $\Delta E > 0$ (artinya solusi baru memberikan efisiensi eksergi yang lebih tinggi, maka solusi baru langsung diterima untuk menggantikan solusi lama. Jika $\Delta E < 0$, solusi tersebut tidak langsung dibuang, melainkan dievaluasi menggunakan Kriteria Penerimaan Metropolis. Setelah sejumlah iterasi pada suhu yang sama selesai dilakukan, suhu sistem diturunkan secara perlahan menggunakan faktor pendinginan (α). Seiring berjalannya waktu dan menurunnya nilai suhu (T), probabilitas untuk menerima solusi yang lebih buruk (P) akan semakin mengecil. Hal ini membuat algoritma SA bertransisi dari mode eksplorasi (acak pada suhu tinggi) menjadi mode eksploitasi (fokus memusat pada suhu rendah). Proses iterasi dan penurunan suhu akan terus berulang hingga sistem mencapai suhu akhir yang ditetapkan (T_{akhir}) atau ketika nilai efisiensi eksergi yang dihasilkan sudah konvergen (tidak mengalami perubahan signifikan lagi). Solusi terbaik yang tercatat selama proses simulasi kemudian diambil sebagai konfigurasi operasional optimal bagi sistem PLTP.

III.3.7 Implementasi Hybrid PSO-SA

Metode optimasi lain pada penelitian ini adalah metode hybrid PSO-SA. Metode ini menggabungkan kemampuan eksplorasi global dari algoritma PSO dan kemampuan pencarian lokal dari SA. Keduanya digunakan secara berurutan, PSO di tahap awal yang berfungsi untuk mengeksplorasi ruang pencarian secara luas, sementara SA digunakan untuk melakukan penghalusan terhadap solusi terbaik yang diperoleh PSO.

Tahap pertama diawali dengan membangkitkan partikel pada ruang yang dibatasi oleh nilai minimum dan maksimum masing-masing parameter yang dioptimasi seperti yang ditunjukkan pada Tabel III.5. Setiap partikel bergerak sebagai satu kandidat solusi yang terdiri atas nilai parameter operasi yang

dioptimasi. Setiap partikel dievaluasi menggunakan fungsi objektif yang telah dibangun. Berdasarkan nilai fungsi objektif tersebut, setiap partikel menyimpan posisi terbaik yang pernah dicapai (*pbest*), sedangkan posisi dengan nilai fungsi objektif terbaik dari seluruh partikel disimpan sebagai *gbest*. Proses tersebut dilakukan secara iteratif hingga mencapai jumlah iterasi yang ditentukan. Setelah seluruh iterasi PSO selesai, posisi dengan nilai fungsi objektif terbaik ditetapkan sebagai *gbest*. Solusi ini kemudian dilanjutkan ke tahap kedua (Javidrad & Nazari, 2017).

Tahap kedua dimulai berdasarkan solusi *gbest* dari algoritma PSO sebagai solusi awal SA. Karena itu, SA tidak digunakan untuk mencari ke seluruh ruang solusi, tapi langsung melakukan pencarian di wilayah sekitar solusi yang telah dianggap cocok oleh PSO. Pada implementasi ini, SA dilakukan untuk 800 iterasi. Kandidat solusi baru dibangkitkan di sekitar solusi saat ini dengan menggunakan radius pencarian sebesar 2% dari rentang masing-masing parameter. Secara konseptual, jika suatu parameter memiliki batas bawah dan batas atas, maka rentang pencariannya adalah

$$R_x = x_{maks} - x_{min} \quad (III.19)$$

Sehingga, ukuran radius pencariannya adalah

$$\Delta x = 0.02R_x \quad (III.20)$$

Kandidat solusi kemudian dibangkitkan di sekitar radius tersebut. Dengan demikian, SA melakukan pencarian dengan langkah yang relatif kecil dibandingkan keseluruhan ruang pencarian. SA memiliki mekanisme probabilistik yang

Tabel III. 63 Parameter algoritma PSO-SA

Parameter Variabel	Variasi		
	1	2	3
Jumlah partikel	30	80	30
Jumlah iterasi PSO	60	60	60
Jumlah iterasi SA	800	800	2000
Bobot inersia (<i>w</i>)	0.7	0.7	0.7

memungkinkan kandidat solusi yang lebih buruk diterima yang dikendalikan oleh parameter algoritma temperatur atau *T*. Semakin rendah temperatur, semakin selektif algoritma dalam menerima solusi buruk. Setelah proses iteasi konvergen, solusi tersebutlah yang dipilih sebagai solusi optimum dari percobaan algoritma hybrid.

BAB IV

HASIL DAN ANALISIS

IV.1 Model Surrogate

IV.1.1 Analisis Korelasi dan Seleksi Fitur

Analisis korelasi dilakukan untuk menentukan parameter operasional yang memiliki variabel prediktor hubungan dengan *net power* sebagai variabel target. Dataset terdiri dari 2,905 titik data dengan 102 kolom, namun hanya terdapat 45 kolom dengan data pengukuran yang tersedia. Karena itu, data operasional dari 45 kolom tersebut perlu diseleksi agar dapat digunakan dalam pembentukan model *surrogate*. Seleksi fitur tidak hanya berdasarkan pada analisis korelasi, namun juga berdasarkan hasil analisis redundansi antarparameter dan multikolinieritas antarvariabel operasional sehingga fitur yang dipertahankan memiliki informasi unik terhadap variabel target.

Tabel IV. 1 Koefisien korelasi untuk setiap parameter terukur

Parameter	Koefisien korelasi
Gross power (MW)	0.996
Laju inlet turbin (T/h)	0.945
Tekanan outlet turbin A (bara)	0.567
Tekanan outlet turbin B (bara)	0.563
Tekanan outlet turbin C (bara)	0.562
Tekanan inlet HWP A (barg)	0.453
Tekanan inlet HWP B (barg)	0.438
Tekanan inlet air ke CT (barg)	0.394
Suhu inlet air ke CT (°C)	0.360
Laju CT-main condenser (m ³ /h)	0.304
⋮	⋮
Tekanan outlet HWP B (barg)	-0.246
Tekanan inlet turbin R (barg)	-0.465

Tabel di atas menunjukkan parameter-parameter dengan koefisien korelasi tertinggi positif hingga tertinggi negatif. Parameter dengan koefisien korelasi tertinggi adalah gross power atau daya kotor. Parameter ini merupakan daya yang

dihasilkan oleh pembangkit sebelum listrik digunakan kembali untuk operasional. Selanjutnya, nilai koefisien korelasi positif tertinggi setelah gross power adalah laju inlet turbin dengan $R = 0.945$. Parameter ini merupakan parameter operasi yang dipengaruhi oleh sistem pengaturan turbin melalui pengaturan bukaan governor valve. Secara termodinamik, daya turbin memang sebanding dengan laju inlet turbin sebagaimana dirumuskan sebagai berikut.


$$\dot{W}_t = m_{in,turbin}(h_{in} - h_{out}) \quad (IV.1)$$

Artinya, ketika kondisi termodinamika uap relatif tetap, kenaikan laju alir massa akan meningkatkan laju energi yang masuk ke turbin, berdasarkan persamaan di atas, laju inlet turbin naik maka kerja turbin juga akan naik, karena itu daya listrik juga akan semakin tinggi. PLTP terhubung ke jaringan listrik, generator menjaga keseimbangan antara daya mekanik dari turbin dan beban listrik yang diminta jaringan. Pada kondisi operasional normal, generator tersinkron mengikuti frekuensi jaringan, sehingga ketika terdapat perubahan beban, maka sistem kemudian menerjemahkan perubahan tersebut menjadi perubahan torsi elektromagnetik yang harus diimbangi oleh torsi turbin. Misal ketika jaringan membutuhkan suplai daya tambahan, beban elektro magnetik generator akan meningkat, governor turbin mendeteksi perubahan kondisi kecepatan kemudian meningkatkan bukaan *control valve*. Akibatnya, *valve* secara langsung mengalirkan uap masuk ke turbin sesuai dengan kebutuhan. Begitu pula sebaliknya ketika jaringan memerlukan penurunan beban.

Secara berturut-turut tekanan outlet turbin A, B, dan C dalam bar absolut menghasilkan koefisien korelasi tertinggi selanjutnya. Pada Gambar III.2 menunjukkan jika ketiga parameter ini diukur pada *streamline* yang sama. Untuk mengeliminasi redundansi parameter, ketiganya dirata-ratakan untuk menjadi hanya satu parameter tekanan outlet turbin. terdapat beberapa parameter dengan lokasi pengukuran sama seperti tekanan outlet turbin A, B, dan C. Untuk mengeliminasi redundansi, dilakukan penyetaraan dengan merata-ratakan ketiga parameter tersebut untuk menentukan nilai koefisien korelasi. Sehingga, didapatkan untuk korelasi antara tekanan outlet turbin dengan daya bersih adalah $R = 0.564$. Berdasarkan persamaan IV.1 kerja turbin ditentukan oleh laju alir massa dan selisih entalpi antara kondisi inlet dan outlet. Semakin besar penurunan entalpi (Δh) yang dapat dikonversi menjadi kerja turbin dan selanjutnya menjadi daya listrik. Tekanan outlet turbin berperan dalam menentukan kondisi termodinamika uap pada akhir proses ekspansi, sehingga perubahan tekanan outlet akan memengaruhi nilai entalpi outlet dan besarnya penurunan entalpi selama ekspansi. Secara sederhana, tekanan outlet yang lebih rendah memungkinkan uap mengalami ekspansi hingga tekanan

yang lebih rendah sehingga, pada kondisi inlet yang sama, penurunan entalpi yang tersedia untuk menghasilkan kerja cenderung lebih besar. Meskipun demikian, hasil analisis data operasional menunjukkan bahwa tekanan outlet turbin memiliki hubungan positif moderat dengan *net power*, dengan koefisien korelasi sebesar $R = 0.564$. Hasil ini tidak dapat langsung diartikan bahwa peningkatan tekanan outlet menyebabkan peningkatan daya keluaran. Pada kondisi operasi aktual, tekanan outlet merupakan bagian dari suatu sistem yang saling berinteraksi dan tidak berubah secara terisolasi. Tekanan tersebut sangat berkaitan dengan kondisi condenser dan sistem pendingin yang berfungsi mempertahankan tekanan rendah pada sisi *exhaust* turbin. Perubahan beban pembangkit juga menyebabkan perubahan laju alir uap dan kondisi operasi turbin, sehingga perubahan tekanan outlet dapat terjadi secara bersamaan dengan perubahan parameter lainnya. Nilai korelasi positif yang diperoleh merupakan hubungan empiris yang terbentuk dari perubahan kondisi operasi secara simultan, bukan hubungan sebab-akibat langsung antara tekanan outlet dan *net power*. Secara termodinamika, pengaruh tekanan outlet tetap dapat dijelaskan melalui pengaruhnya terhadap kondisi akhir ekspansi dan entalpi outlet, sedangkan secara statistik tanda dan besar korelasi yang diamati mencerminkan respons keseluruhan sistem pembangkit pada kondisi operasi aktual.

Parameter dengan koefisien korelasi absolut tertinggi berikutnya adalah tekanan inlet turbin dengan $R = -0.465$ dan tekanan inlet HWP A & B setelah kedua nilai sensor ini dirata-ratakan didapat $R = 0.461$. Keduanya memiliki koefisien korelasi dengan kategori moderat. Berdasarkan karakteristik persebaran data, tekanan inlet turbin memiliki nilai yang tidak banyak bervariasi, karena parameter ini cenderung dipertahankan oleh sistem sejak uap keluar dari sumur. Sementara tekanan HWP secara operasional memiliki jalur alir yang sama dengan tekanan outlet turbin yang mengakibatkan kedua nilai korelasi antara tekanan outlet turbin dan tekanan inlet HWP memiliki koefisien korelasi yang tinggi, artinya kedua parameter ini secara statistik menceritakan hal yang sama. Berdasarkan perhitungan VIF, nilai VIF untuk tekanan outlet turbin adalah $VIF = 12.4$ dan tekanan inlet HWP dengan $VIF = 9.18$. Sehingga, dipilih salah satu dari kedua fitur tersebut untuk diaplikasikan ke dalam model, yaitu tekanan outlet turbin. Sehingga, VIF untuk tekanan outlet turbin menjadi $VIF = 2.13$ yang berada di dalam batas aman. Berdasarkan visualisasi *heatmap* dapat dilihat parameter-parameter dengan koefisien korelasi tinggi yang berarti parameter tersebut merupakan parameter redundan. *Heatmap* untuk seluruh parameter yang terukur



Gambar IV. 1 Heatmap koefisien korelasi untuk 45 parameter terukur di PLTP

ditampilkan pada gambar di bawah ini.

Berdasarkan analisis korelasi, dihasilkan fitur yang dipilih adalah laju inlet turbin dengan $R = 0.945$ dan tekanan outlet turbin dengan $R = 0.564$.

IV.1.2 Data Preprocessing

Data operasional yang digunakan dalam pemodelan terlebih dahulu melalui tahap data preprocessing untuk memastikan bahwa data yang masuk ke tahap analisis memiliki kualitas yang memadai. Pemeriksaan awal dilakukan terhadap keberadaan nilai nol yang dianggap tidak sesuai dengan karakteristik pengukuran parameter operasional. Nilai nol pada sensor dalam konteks ini diperlakukan sebagai indikasi sensor dropout, bukan sebagai kondisi operasi aktual.

Hasil pemeriksaan menunjukkan terdapat 5 baris data yang mengandung setidaknya satu nilai nol pada parameter operasional yang diperiksa. Kelima baris tersebut kemudian dihapus dari dataset. Setelah proses tersebut, jumlah data berubah menjadi 2,900 baris dengan 47 kolom. Penghapusan dilakukan karena nilai

nol pada parameter operasi tertentu dapat menghasilkan representasi kondisi pembangkit yang tidak fisik dan berpotensi mengganggu analisis hubungan antarparameter maupun proses pelatihan model regresi.

Tahap berikutnya adalah pemeriksaan outlier pada variabel yang digunakan dalam pemodelan, yaitu laju inlet turbin, tekanan outlet turbin, dan net power. Deteksi outlier dilakukan menggunakan metode Interquartile Range (IQR). Metode ini menggunakan kuartil pertama (Q_1) dan kuartil ketiga (Q_3) sebagai dasar untuk menentukan rentang data tengah. IQR dihitung dengan

$$IQR = Q_3 - Q_1.$$

Dalam penelitian ini digunakan batas yang lebih longgar, yaitu $3IQR$, sehingga suatu pengamatan dikategorikan sebagai outlier apabila berada di luar batas


$$x < Q_1 - 3IQR$$

atau

$$x > Q_3 + 3IQR.$$

Pemilihan $k = 3$ dilakukan agar proses pembersihan tidak terlalu agresif terhadap data operasional. Hal ini penting karena nilai yang jauh dari pusat distribusi pada data PLTP tidak selalu merupakan kesalahan pengukuran, tetapi dapat merepresentasikan kondisi operasi pembangkit yang memang terjadi.

Hasil pemeriksaan menunjukkan bahwa setelah penerapan batas $Q_1 - 3IQR$ dan $Q_3 + 3IQR$, tidak terdapat data yang teridentifikasi sebagai outlier. Jumlah data tetap 2.900 baris setelah proses tersebut. Hasil ini menunjukkan bahwa pengamatan yang berada pada bagian ekstrem distribusi masih berada dalam rentang statistik yang diterima berdasarkan kriteria IQR yang digunakan. Dengan demikian, tidak terdapat alasan statistik untuk menghapus pengamatan tambahan pada tahap ini.



Gambar IV. 2 Visualisasi boxplot persebaran data variabel prediktif dan variabel target


Hasil tersebut juga terlihat pada visualisasi boxplot. Boxplot digunakan untuk melihat median, rentang interkuartil, serta pengamatan yang berada di luar batas

distribusi. Pada ketiga variabel yang digunakan, yaitu laju inlet turbin, tekanan outlet turbin, dan net power, tidak terdapat titik observasi yang teridentifikasi sebagai outlier berdasarkan kriteria yang diterapkan. Posisi median dan rentang interkuartil menunjukkan bahwa sebagian besar data terkonsentrasi pada rentang operasi normal, sedangkan variasi pada bagian atas dan bawah distribusi masih berada dalam batas $3IQR$.


Dengan demikian, proses preprocessing menghasilkan dataset akhir sebanyak 2,900 pengamatan, yang selanjutnya digunakan dalam tahap Exploratory Data Analysis. Hasil preprocessing juga menunjukkan bahwa perubahan jumlah data terutama disebabkan oleh penghapusan lima observasi sensor dropout, sedangkan tidak terdapat pengurangan data akibat deteksi outlier. Kondisi ini penting untuk dipertahankan karena sebagian besar variasi kondisi.

IV.1.3 Exploratory Data Analysis (EDA)

Dilakukan Exploratory Data Analysis (EDA) untuk memahami karakteristik data operasional PLTP dan pola perubahan net power selama periode pengamatan. Berdasarkan visualisasi time series, parameter operasi dan net power menunjukkan fluktuasi sepanjang periode pengamatan, yang menunjukkan bahwa pembangkit tidak beroperasi pada satu kondisi yang benar-benar tetap. Variasi net power berada pada kisaran sekitar 53 sampai 62 MW dengan sebagian besar pengamatan terkonsentrasi pada rentang operasi sekitar 56 sampai 61 MW. Konsentrasi tersebut menunjukkan bahwa pembangkit lebih sering beroperasi di sekitar kondisi operasional normal, sedangkan nilai yang lebih rendah maupun lebih tinggi terjadi pada kondisi yang lebih jarang. Fluktuasi daya yang terlihat pada time series juga tidak selalu mengikuti perubahan satu parameter secara identik, sehingga menunjukkan bahwa net power merupakan respons gabungan dari beberapa kondisi operasi sistem.




Gambar IV. 3 Visualisasi fluktuasi beban terhadap waktu



Gambar IV. 4 Visualisasi persebaran rentang net power

Distribusi net power memperlihatkan pola yang relatif terkonsentrasi pada rentang operasi utama tersebut. Hal ini penting dalam pembentukan model regresi karena model akan memiliki jumlah informasi yang lebih banyak untuk mempelajari pola pada kondisi operasi yang sering terjadi dibandingkan kondisi ekstrem. Dengan demikian, performa model nantinya perlu dipahami dalam konteks distribusi data ini. Prediksi yang baik pada rentang daya dominan belum tentu memberikan tingkat akurasi yang sama pada kondisi dengan jumlah observasi lebih sedikit. Namun, karena observasi pada kondisi daya rendah dan tinggi tetap dipertahankan selama preprocessing, model masih memiliki kesempatan untuk mempelajari variasi respons pembangkit pada rentang operasi yang lebih luas. Gambar berganda umumnya berpola baris dan kolom, atau panel baris dan panel kolom. Setiap panel dapat mewakili kelas tertentu, yang berbeda dengan panel.

Hubungan antara fitur yang akhirnya dipilih dengan *net power* dianalisis menggunakan *scatter plot*. Laju inlet turbin menunjukkan pola titik yang paling teratur membentuk kecenderungan meningkat. Sebaran yang relatif mengikuti arah garis tren memperkuat hasil korelasi dan menunjukkan bahwa variabel tersebut mampu menjelaskan sebagian besar variasi daya secara empiris. Sebaliknya, titik pada hubungan tekanan outlet turbin dengan *net power* terlihat lebih menyebar. Kondisi ini konsisten dengan korelasinya yang lebih rendah dan menunjukkan bahwa pengaruh parameter tersebut terhadap daya lebih kompleks serta kemungkinan berinteraksi dengan kondisi operasi lainnya.



Gambar IV. 5 Persebaran variabel prediktif terhadap net power

Secara keseluruhan, hasil EDA menunjukkan bahwa *net power* pada dataset tidak berubah secara acak, tetapi memiliki pola yang berkaitan erat dengan kondisi operasi turbin. Laju inlet turbin menjadi parameter yang paling dominan secara statistik sekaligus memiliki hubungan fisis langsung dengan besarnya energi yang diproses turbin. Tekanan outlet turbin memberikan informasi tambahan mengenai kondisi ekspansi dan perubahan *enthalpy drop*. Kombinasi keduanya memberikan representasi yang cukup sederhana tetapi tetap memiliki dasar fisis terhadap proses pembangkitan daya, sehingga kedua parameter tersebut digunakan sebagai fitur masukan dalam pembentukan model *surrogate* Polynomial Regression:

$$P_{net} = f(\dot{m}_{in,turb}, P_{out,turb}) \quad (IV.2)$$

Berdasarkan data hasil pengamatan, laju inlet turbin berada pada rentang 371.85 sampai 447.01 T/h, sedangkan tekanan outlet turbin berada pada rentang 0.124 sampai 0.1623 bara. Rentang tersebut merepresentasikan variasi kondisi operasi aktual yang terjadi selama periode pengamatan. Rentang data operasional tersebut digunakan sebagai batas awal dalam proses pencarian solusi oleh algoritma optimasi. algoritma optimasi PSO, SA, dan hybrid tidak mencari solusi pada ruang parameter yang tidak memiliki representasi dalam data historis, tetapi dibatasi pada rentang kondisi operasi yang telah diamati. Pembatasan ini juga menjadi dasar dalam penerapan *trust region* menggunakan jarak Mahalanobis, sehingga kandidat solusi yang dihasilkan tidak hanya berada dalam batas minimum dan maksimum masing-masing parameter, tetapi juga tetap berada pada wilayah distribusi multivariat data operasional yang digunakan untuk membangun model *surrogate*.

Dengan pendekatan tersebut, proses optimasi diarahkan untuk mencari kombinasi $\dot{m}_{in,turb}$ dan $P_{out,turb}$ yang memberikan *net power* maksimum dengan tetap mempertahankan keterkaitannya terhadap kondisi operasi aktual PLTP.

IV.1.4 Train-Test Split dan Hyperparameter Tuning

Setelah diperoleh dua fitur terpilih, yaitu laju inlet turbin dan tekanan outlet turbin, dataset selanjutnya dibagi menjadi data *training* dan *testing* dengan proporsi 80% dan 20%. Data *training* digunakan untuk membentuk model regresi sekaligus menentukan konfigurasi model yang sesuai, sedangkan data *testing* disimpan dan tidak digunakan selama proses pemilihan model. Pembagian ini dilakukan agar kemampuan model dalam memprediksi data yang belum digunakan selama proses pembelajaran dapat dievaluasi secara independen.

Selanjutnya dilakukan hyperparameter tuning untuk menentukan orde polinomial (*degree*) yang paling sesuai pada model Polynomial Regression. Berdasarkan implementasi pada notebook, kandidat orde yang diuji adalah degree 1 hingga 5. Setiap kandidat orde digunakan untuk mentransformasikan dua fitur

Tabel IV. 2 Pengaruh derajat polinom terhadap model


Derajat polinom	Jumlah suku	R ² latih	R ² validasi	RMSE validasi
1	2	0.925	0.924	0.520
2	5	0.931	0.931	0.499
3	9	0.947	0.945	0.445
4	14	0.950	0.948	0.432
5	20	0.960	0.920	0.498

terpilih ke dalam bentuk polinomial, kemudian model regresi dibentuk berdasarkan data *training*. Performa setiap kandidat dibandingkan menggunakan *5-fold cross-validation*, sehingga setiap model dievaluasi pada beberapa bagian data *training* secara bergantian.

Pemilihan orde dilakukan dengan mempertimbangkan nilai validasi dan RMSE validasi. Nilai yang lebih tinggi menunjukkan kemampuan model yang lebih baik dalam menjelaskan variasi *net power*, sedangkan RMSE yang lebih rendah menunjukkan kesalahan prediksi yang lebih kecil. Dengan membandingkan kedua metrik tersebut pada setiap orde, dapat ditentukan tingkat kompleksitas model yang paling sesuai tanpa menggunakan data *testing* sebagai dasar pemilihan.

Hasil pengujian menunjukkan bahwa peningkatan orde polinom dari degree 1 hingga degree 4 memberikan peningkatan performa validasi. Pada degree 4, diperoleh nilai validasi tertinggi sekitar 0.948 dan RMSE validasi terendah sekitar 0.433 MW. Ketika orde dinaikkan menjadi derajat 5, performa validasi justru

menurun, meskipun performa pada data *training* meningkat. Hal ini menunjukkan bahwa penambahan kompleksitas pada degree 5 tidak lagi memberikan kemampuan generalisasi yang lebih baik dan mulai mengindikasikan *overfitting*.



Gambar IV. 6 Pengaruh derajat polinom terhadap R-square dan RMSE

Berdasarkan hasil tersebut, degree 4 dipilih sebagai konfigurasi model Polynomial Regression final. Model dengan konfigurasi tersebut kemudian digunakan pada tahap evaluasi menggunakan data *testing* untuk mengukur kemampuan model dalam memprediksi *net power* pada data yang belum digunakan selama proses pembentukan dan pemilihan model.

IV.1.5 Model Hasil dan Evaluasi

Berdasarkan hasil *hyperparameter tuning*, model *surrogate* yang dipilih adalah Polynomial Regression derajat 4 dengan dua variabel prediktor, yaitu laju inlet turbin dan tekanan outlet turbin. Model kemudian dilatih menggunakan 80% dataset atau sebanyak 2,320 pengamatan, sedangkan 580 pengamatan lainnya digunakan sebagai data pengujian. Pembagian dilakukan dengan random state = 42 sehingga hasil pembagian data dapat direproduksi. Hasil pelatihan dan pengujian model disajikan pada Tabel IV.3.

Hasil evaluasi menunjukkan bahwa model memiliki performa yang relatif konsisten antara data *training* dan *testing*. Nilai R^2 pada data *training* sebesar 0.9498 dan meningkat sedikit menjadi 0.9508 pada data *testing*. Perbedaan kedua nilai tersebut hanya sekitar 0.001, sehingga tidak ditemukan penurunan performa yang berarti ketika model diterapkan pada data yang tidak digunakan selama pelatihan. Kondisi ini penting karena menunjukkan bahwa model tidak hanya mampu menyesuaikan pola pada data training, tetapi juga mempertahankan kemampuan prediktifnya pada data baru.

Nilai $R^2 = 0.9508$ menunjukkan bahwa sekitar 95.08% variasi *net power*

Tabel IV. 3 Evaluasi statistik pada model regresi


Tahap	R^2	MAE	RMSE	MAPE
Train	0.950	0.331 MW	0.425 MW	0.56%
Test	0.951	0.337 MW	0.429 MW	0.57%

pada data testing dapat dijelaskan oleh model berdasarkan dua parameter yang digunakan, sedangkan sekitar 4.92% variasi sisanya tidak dijelaskan oleh model. Sisa variasi tersebut secara fisik dapat berasal dari kondisi operasi lain yang tidak dimasukkan sebagai prediktor, fluktuasi sistem, karakteristik generator dan peralatan bantu, maupun variasi pengukuran. Dengan demikian, nilai R^2 yang tinggi menunjukkan bahwa dua fitur yang dipilih sudah mampu merepresentasikan sebagian besar pola perubahan *net power*, tetapi belum berarti bahwa seluruh perilaku daya pembangkit dapat dijelaskan hanya dengan kedua parameter tersebut. MAE pada data testing sebesar 0.3372 MW menunjukkan bahwa secara rata-rata prediksi model berbeda sekitar 0.34 MW dari nilai aktual. Dengan daya operasi PLTP yang umumnya berada pada kisaran puluhan megawatt, error rata-rata tersebut relatif kecil. Nilai MAE juga hampir sama dengan hasil pada data training, yaitu 0.3306 MW. Perbedaan yang sangat kecil ini kembali menunjukkan bahwa performa model tidak mengalami degradasi yang berarti ketika digunakan pada data testing.

Sementara itu, RMSE pada data testing sebesar 0.4286 MW sedikit lebih tinggi dibandingkan MAE, yaitu 0.3372 MW. Selisih tersebut menunjukkan adanya beberapa pengamatan dengan error yang lebih besar daripada error tipikal model. Hal ini sesuai dengan sifat RMSE yang memberikan penalti lebih besar terhadap residual dengan nilai absolut tinggi. Dengan demikian, meskipun sebagian besar prediksi memiliki error sekitar beberapa ratus kilowatt, terdapat sebagian kecil

pengamatan yang menyimpang lebih jauh dan berkontribusi lebih besar terhadap nilai RMSE.


Nilai MAPE sebesar 0.57% memberikan gambaran relatif terhadap besarnya daya aktual. Dengan kata lain, kesalahan prediksi rata-rata berada pada orde kurang dari 1% terhadap nilai aktual. Nilai ini memperkuat bahwa kesalahan model relatif kecil dibandingkan magnitudo *net power* pada dataset pengujian. Namun, MAPE tetap perlu dibaca bersama MAE dan RMSE karena metrik berbasis persentase dapat memberikan interpretasi yang berbeda ketika nilai target sangat kecil.



Gambar IV. 7 Persebaran data aktual terhadap prediksi model

Performa model kemudian dianalisis secara visual melalui hubungan antara nilai *net power* aktual dan hasil prediksi. Pada Gambar X, sebagian besar titik pengamatan berada di sekitar garis ideal $y = x$, terutama pada rentang daya tempat jumlah pengamatan paling banyak. Pola ini menunjukkan bahwa model mampu

mengikuti variasi utama target dengan baik. Konsentrasi titik yang cukup dekat dengan garis ideal juga konsisten dengan nilai MAE dan RMSE yang relatif kecil. Akan tetapi, penyebaran titik tidak sepenuhnya seragam pada seluruh rentang *net power*. Beberapa pengamatan pada kondisi daya yang lebih rendah menunjukkan prediksi yang cenderung lebih tinggi daripada nilai aktual, sedangkan pada beberapa kondisi daya yang lebih tinggi terlihat penyimpangan ke kedua arah. Hal ini menunjukkan bahwa model memiliki akurasi yang baik secara umum, tetapi tingkat kesalahannya bergantung pada kondisi operasi. Dengan kata lain, hubungan antara laju inlet turbin, tekanan outlet turbin, dan *net power* tidak sepenuhnya direpresentasikan oleh satu pola yang memiliki error konstan pada seluruh rentang operasi.



Gambar IV. 8 Distribusi residual dengan hasil prediksi

Pola tersebut diperiksa lebih lanjut melalui grafik residual. Residual didefinisikan sebagai:

$$e_i = P_{net,i} - \hat{P}_{net,i}$$

Sebagian besar residual berada di sekitar garis nol, yang menunjukkan bahwa prediksi model secara umum tidak mengalami bias sistematis yang sangat besar. Namun, terdapat beberapa titik dengan residual negatif yang cukup besar serta beberapa residual positif yang lebih tinggi daripada penyimpangan mayoritas data. Keberadaan titik-titik tersebut menjelaskan mengapa RMSE lebih besar dibandingkan MAE. Dengan kata lain, model secara umum bekerja baik, tetapi terdapat sejumlah kondisi operasi tertentu yang lebih sulit diprediksi.

Histogram residual juga menunjukkan bahwa sebagian besar error terkonsentrasi di sekitar nol. Hal tersebut merupakan karakteristik yang diharapkan dari model prediktif yang baik karena menunjukkan bahwa sebagian besar prediksi mendekati nilai aktual. Di sisi lain, ekor distribusi residual menunjukkan adanya sejumlah kecil pengamatan dengan error yang lebih besar. Karena jumlahnya relatif sedikit, pengamatan tersebut tidak mendominasi pola umum model, tetapi tetap memberikan kontribusi terhadap nilai RMSE.

Jika hasil evaluasi numerik dan visual dianalisis secara bersamaan, model Polynomial Regression derajat 4 menunjukkan generalization performance yang baik. Hal ini terutama terlihat dari tiga hal. Pertama, R^2 testing sebesar 0,9508 hampir identik dengan R^2 training sebesar 0.9498. Kedua, MAE dan RMSE testing hanya sedikit lebih besar dibandingkan training. Ketiga, residual secara umum tersebar di sekitar nol tanpa indikasi kuat bahwa model hanya cocok untuk data training.

Menariknya, hasil evaluasi model akhir juga memperlihatkan bahwa model yang lebih sederhana dengan hanya dua fitur tetap mampu mencapai R^2 sekitar 0.95. Hal ini menjadi hasil penting dari proses seleksi fitur. Model tidak perlu menggunakan seluruh parameter operasional untuk mendapatkan kemampuan prediksi yang tinggi. Laju inlet turbin dan tekanan outlet turbin sudah membawa informasi utama yang dibutuhkan model untuk merepresentasikan perubahan *net power* pada rentang kondisi operasi yang terdapat dalam dataset.


Meskipun demikian, nilai performa yang tinggi tidak berarti model dapat digunakan tanpa batas pada sembarang kondisi operasi. Model dibangun berdasarkan data historis, sehingga prediksi paling dapat dipercaya pada rentang kondisi yang masih direpresentasikan oleh data training. Hal ini menjadi penting terutama ketika model digunakan pada tahap berikutnya untuk melakukan *what-if analysis*. Variasi parameter yang diberikan kepada model harus tetap berada pada wilayah operasi yang memiliki dukungan data historis agar model melakukan interpolasi, bukan ekstrapolasi yang berpotensi menghasilkan prediksi yang tidak realistis.

Secara keseluruhan, model Polynomial Regression derajat 4 dengan dua fitur memberikan hasil prediksi yang baik dengan $R^2 = 0.9508$, $MAE = 0.3372$ MW, $RMSE = 0.4286$ MW, dan $MAPE = 0.57\%$ pada data testing. Hasil tersebut menunjukkan bahwa model mampu merepresentasikan hubungan empiris antara laju inlet turbin, tekanan outlet turbin, dan *net power* dengan tingkat kesalahan relatif kecil. Model ini selanjutnya digunakan sebagai *surrogate model* untuk memprediksi perubahan *net power* pada berbagai kombinasi kondisi operasi dalam rentang data yang tersedia.

IV.2 Optimasi dengan Metode PSO

Optimasi pertama yang dilakukan adalah dengan metode PSO, dengan konfigurasi pertama pada tabel III.3. Setiap partikel merepresentasikan nilai dari 2 fitur/partikel yang diperoleh dari model *surrogate*, yaitu laju inlet turbin dan tekanan outlet turbin. Evaluasi setiap posisi partikel dilakukan menggunakan prediksi *net power*


dari model regresi polinomial derajat 4 dengan batasan *trust-region* berdasarkan jarak Mahalanobis.



Gambar IV. 9 Konvergensi dan diversitas partikel dalam optimasi PSO

Hasil optimasi menunjukkan bahwa PSO memperoleh nilai daya optimum sebesar 61.4704 MW dengan nilai jarak Mahalanobis sebesar 1.9211. Nilai tersebut masih berada di dalam *trust-region* yang telah ditetapkan, sehingga solusi yang diperoleh tidak hanya memberikan nilai prediksi daya yang tinggi, tetapi juga masih berada pada wilayah yang memiliki kedekatan statistik dengan distribusi data historis. Hal ini penting karena tanpa pembatasan tersebut, model regresi berpotensi memberikan nilai prediksi tinggi pada wilayah yang jauh dari data aktual dan bersifat ekstrapolatif.

Perilaku konvergensi PSO menunjukkan bahwa algoritma mencapai nilai yang sangat dekat dengan solusi akhirnya hanya dalam 8 iterasi, meskipun proses optimasi tetap dilanjutkan hingga 100 iterasi. Dengan kata lain, sebagian besar peningkatan performa terjadi pada tahap awal iterasi, sedangkan iterasi selanjutnya terutama digunakan untuk mempertahankan dan mengonfirmasi solusi terbaik yang telah ditemukan. Pola ini menunjukkan bahwa lanskap fungsi objektif pada ruang pencarian dua dimensi relatif mudah dijelajahi oleh swarm.



Gambar IV. 10 Diversitas partikel terhadap iterasi

Visualisasi diversitas swarm memberikan penjelasan tambahan terhadap perilaku tersebut. Pada awal optimasi, posisi partikel masih tersebar pada ruang pencarian sehingga diversitas swarm relatif tinggi. Seiring bertambahnya iterasi, partikel semakin terkonsentrasi pada wilayah solusi terbaik dan diversitas turun

secara tajam hingga mendekati nol. Penurunan diversitas ini menunjukkan bahwa swarm secara kolektif telah kehilangan kebutuhan untuk menjelajahi wilayah lain karena informasi dari *pbest* dan *gbest* mengarahkan partikel menuju wilayah yang sama.

Perbandingan antara *global best* dan rata-rata *personal best* juga menunjukkan bahwa konvergensi bukan hanya disebabkan oleh satu partikel yang secara kebetulan menemukan solusi terbaik. Rata-rata *personal best* seluruh partikel bergerak mendekati *global best* selama iterasi. Artinya, sebagian besar partikel secara bertahap menemukan bahwa wilayah solusi yang sama memberikan nilai objektif yang lebih baik. Dengan demikian, konvergensi PSO pada kasus ini merupakan perilaku kolektif seluruh swarm, bukan hanya keberhasilan satu kandidat solusi. Hasil ini juga menunjukkan bahwa 30 partikel dan 100 iterasi sudah lebih dari cukup untuk kasus yang digunakan dalam penelitian ini. Walaupun iterasi maksimum ditetapkan sebanyak 100, solusi akhir telah tercapai jauh sebelum batas tersebut.

Untuk melihat apakah hasil bergantung pada konfigurasi parameter dalam algoritma, ditinjau variasi lain dalam percobaan ini. Variasi parameter ditampilkan pada tabel dengan hasil sebagai berikut.

Hasil yang paling menonjol adalah ketiga konfigurasi menghasilkan nilai

Tabel IV. 4 Hasil optimasi PSO untuk 3 variasi

Variasi	Jumlah Partikel	w	Daya Optimum (MW)	Iterasi dekat solusi	Iterasi konvergen	Evaluasi fungsi
1	30	0.7	61.4704	8	49	3030
2	80	0.7	61.4704	5	58	8080
3	30	0.95	61.4704	12	90	3030

optimum yang identik hingga empat angka desimal, yaitu 61.4704 MW. Dengan kata lain, perubahan jumlah partikel dari 30 menjadi 80 maupun peningkatan bobot inersia dari 0.70 menjadi 0.95 tidak mengubah solusi akhir yang ditemukan. Hal ini menunjukkan bahwa solusi optimum pada kasus ini relatif robust terhadap perubahan parameter PSO. Pengaruh dari variasi jumlah partikel terlihat jelas pada kecepatan dan pola konvergensi.


Ketika jumlah partikel dinaikkan dari 30 menjadi 80, variasi kedua mencapai nilai yang berada dalam jarak kurang dari 0.001 MW dari solusi akhir hanya dalam 5 iterasi, lebih cepat dibandingkan variasi pertama yang membutuhkan

8 iterasi. Penurunan jumlah iterasi ini dapat dipahami karena swarm yang lebih besar mengandung lebih banyak kandidat solusi pada tahap inisialisasi. Akibatnya, peluang terdapatnya partikel yang sejak awal berada dekat dengan wilayah optimum menjadi lebih besar.

Namun, keuntungan tersebut tidak berarti variasi kedua lebih efisien secara keseluruhan. Jumlah evaluasi fungsi meningkat dari 3,030 menjadi 8,080, atau sekitar 167% lebih banyak. Secara waktu komputasi, konfigurasi dengan 80 partikel juga membutuhkan waktu lebih lama. Artinya, penambahan jumlah partikel memang mempercepat konvergensi jika ukuran diukur berdasarkan jumlah iterasi, tetapi dibayar dengan peningkatan beban komputasi yang cukup besar karena setiap iterasi harus mengevaluasi lebih banyak partikel.

Dengan kata lain, pada kasus ini penambahan partikel menghasilkan lebih banyak eksplorasi paralel tetapi tidak menghasilkan solusi akhir yang lebih baik. Karena ruang pencarian hanya terdiri atas dua dimensi dan optimum relatif mudah ditemukan, tambahan 50 partikel tidak memberikan keuntungan kualitas yang berarti.

Berbeda dengan peningkatan jumlah partikel, peningkatan bobot inersia dari 0.70 menjadi 0.95 memberikan pengaruh yang lebih jelas terhadap perilaku pergerakan swarm. Variasi ketiga baru mencapai jarak kurang dari 0.001 MW dari solusi akhirnya pada iterasi ke-12, dibandingkan iterasi ke-8 pada konfigurasi dasar. Selain itu, perbaikan *global best* pada PSO variasi 3 masih berlangsung hingga sekitar iterasi ke-90, sedangkan pada variasi pertama perbaikan terakhir terjadi sekitar iterasi ke-49.



Gambar IV. 11 Konvergensi dan diversitas untuk setiap variasi

Hal tersebut menunjukkan bahwa nilai w yang lebih tinggi membuat partikel mempertahankan sebagian besar momentum pergerakan sebelumnya. Akibatnya, partikel tidak segera berhenti atau terkonsentrasi pada wilayah *gbest*, tetapi tetap bergerak dan menjelajahi ruang pencarian lebih lama. Dalam konteks algoritma, perilaku tersebut meningkatkan kecenderungan eksplorasi, tetapi memperlambat proses eksploitasi menuju solusi yang sudah ditemukan.

Menariknya, peningkatan eksplorasi tersebut tidak memberikan peningkatan terhadap nilai optimum. Variasi ketiga tetap berakhir pada 61.4704 MW, sama dengan variasi pertama dan kedua. Artinya, eksplorasi tambahan akibat $w = 0.95$ tidak menemukan wilayah yang menghasilkan daya lebih tinggi karena optimum yang sama sudah dapat ditemukan dengan parameter dasar.

Nilai jarak Mahalanobis akhir juga hanya berubah sedikit pada variasi ketiga, dari sekitar 1.9211 menjadi 1.9253. Perubahan kecil tersebut menunjukkan bahwa meskipun lintasan pencarian berbeda, seluruh konfigurasi akhirnya tetap menuju wilayah solusi yang hampir sama secara statistik.

IV.3 Optimasi dengan Metode SA

Pada tahap optimasi menggunakan *Simulated Annealing* (SA), dilakukan tiga konfigurasi algoritma dengan memvariasikan temperatur awal T_0 dan faktor pendinginan α , sedangkan ukuran langkah (*step fraction*), jumlah iterasi, dan *random seed* dipertahankan tetap. Ketiga konfigurasi tersebut adalah variasi pertama sebagai baseline dengan $T_0 = 10$ dan $\alpha = 0.995$, variasi kedua dengan peningkatan temperatur awal menjadi $T_0 = 50$, serta variasi ketiga dengan perlambatan proses pendinginan melalui peningkatan α menjadi 0.999. Jumlah iterasi ditetapkan sebanyak 2,000 pada seluruh konfigurasi. Pengaturan ini memungkinkan pengaruh T_0 dan α diamati secara lebih terisolasi.

Tabel IV. 5 Hasil optimasi SA untuk 3 variasi

Variasi	T_0	α	Daya Optimum (MW)	Mahalanobis	Accept rate total
1	10	0.995	61.4703	1.9223	0.430
2	50	0.995	61.4701	1.9249	0.580
3	10	0.999	61.4698	1.8935	0.885

Hasil optimasi menunjukkan bahwa ketiga konfigurasi SA menghasilkan daya optimum yang hampir identik, yaitu berada pada rentang 61.4698 sampai 61.4703 MW. Selisih antara hasil tertinggi dan terendah hanya sekitar 0.0005 MW, sehingga perubahan temperatur awal maupun laju pendinginan tidak memberikan perubahan berarti terhadap kualitas solusi akhir. Temuan ini menunjukkan bahwa solusi optimum pada ruang pencarian yang digunakan relatif robust terhadap variasi parameter SA.

Meskipun nilai optimum hampir sama, perubahan parameter algoritma memberikan pengaruh yang jelas terhadap mekanisme pencarian solusi, yang

tercermin dari tingkat penerimaan (*acceptance rate*) masing-masing konfigurasi. Pada variasi pertama, *acceptance rate* sebesar 43.0%, yang berarti sekitar 43% kandidat solusi diterima selama proses optimasi. Nilai ini menunjukkan bahwa algoritma masih cukup sering menerima perpindahan solusi, termasuk perpindahan menuju solusi yang lebih buruk sesuai mekanisme probabilistik SA. Kondisi tersebut memungkinkan algoritma tetap melakukan eksplorasi terhadap ruang solusi, sementara temperatur secara bertahap diturunkan untuk mengarahkan pencarian menuju wilayah solusi yang lebih baik.


Ketika temperatur awal dinaikkan dari $T_0 = 10$ menjadi $T_0 = 50$ pada variasi kedua, *acceptance rate* meningkat menjadi 58.0%. Kenaikan tersebut sesuai dengan mekanisme penerimaan SA. Pada temperatur yang lebih tinggi, probabilitas untuk menerima solusi yang memiliki nilai objektif lebih buruk menjadi lebih besar karena faktor probabilitas Metropolis bergantung pada temperatur. Akibatnya, variasi kedua lebih permisif terhadap perpindahan yang tidak memberikan peningkatan langsung terhadap fungsi objektif. Dalam konteks pencarian, hal tersebut berarti eksplorasi pada tahap awal menjadi lebih agresif.

Namun, kenaikan *acceptance rate* tersebut tidak menghasilkan peningkatan nilai optimum. Daya optimum variasi kedua sebesar 61.4701 MW justru sedikit lebih rendah daripada variasi pertama sebesar 61.4703 MW, dengan selisih yang sangat kecil dan tidak signifikan secara praktis. Hal ini menunjukkan bahwa eksplorasi tambahan yang dihasilkan oleh temperatur awal yang lebih tinggi tidak menemukan wilayah solusi yang lebih baik daripada yang sudah ditemukan oleh konfigurasi baseline. Dengan kata lain, pada permasalahan ini, variasi pertama sudah memiliki kemampuan eksplorasi yang cukup untuk mencapai wilayah optimum.

Pengaruh yang lebih kuat terlihat pada variasi ketiga ketika faktor pendinginan diubah dari $\alpha = 0.995$ menjadi 0.999. Karena

$$T_{k+1} = \alpha T_k,$$

Nilai α yang lebih dekat dengan satu menyebabkan temperatur berkurang lebih lambat. Dengan demikian, temperatur efektif tetap tinggi lebih lama selama proses optimasi. Kondisi tersebut menyebabkan mekanisme penerimaan solusi yang lebih buruk tetap aktif sepanjang periode pencarian yang lebih panjang. Hal ini tercermin sangat jelas pada *acceptance rate* variasi ketiga yang mencapai 88.5%, jauh lebih tinggi dibandingkan 43.0% pada variasi pertama.



Gambar IV. 12 Konvergensi, skema pendinginan, dan tingkat penerimaan solusi lebih buruk untuk ketiga variasi

Secara intuitif, variasi ketiga dapat dikatakan lebih "sabar" dalam meninggalkan solusi saat ini. algoritma tidak cepat mengunci diri pada suatu wilayah, karena temperatur masih cukup tinggi sehingga perpindahan ke solusi yang lebih buruk masih sering diperbolehkan. Strategi ini meningkatkan eksplorasi dan mengurangi kecenderungan algoritma untuk terlalu cepat berhenti pada solusi lokal. Namun, konsekuensinya adalah proses eksploitasi menjadi lebih lambat karena algoritma tetap menerima banyak perpindahan meskipun wilayah solusi yang baik sebenarnya sudah ditemukan.

Hal tersebut terlihat dari hasil akhirnya. Walaupun variasi ketiga melakukan eksplorasi jauh lebih agresif, daya optimum yang diperoleh hanya 61.4698 MW, sedikit lebih rendah daripada dua konfigurasi lainnya. Dengan demikian, peningkatan eksplorasi melalui pendinginan yang lebih lambat tidak memberikan keuntungan terhadap kualitas solusi pada kasus ini.

Visualisasi konvergensi *best-so-far* memperlihatkan bahwa ketiga konfigurasi akhirnya menuju nilai daya yang sama. Perbedaan terutama muncul pada bentuk lintasan menuju solusi tersebut. Konfigurasi dengan temperatur lebih tinggi atau pendinginan yang lebih lambat mempertahankan kemampuan berpindah antarwilayah solusi lebih lama, sehingga kurva pencariannya cenderung lebih berfluktuasi sebelum akhirnya stabil. Sebaliknya, konfigurasi baseline dengan pendinginan yang lebih cepat lebih cepat mengurangi ruang eksplorasinya dan kemudian mempertahankan solusi terbaik yang telah ditemukan.

Pola tersebut konsisten dengan grafik temperatur. Perbedaan perilaku pencarian yang cukup besar tersebut tidak menghasilkan perbedaan solusi akhir yang berarti. Hal ini menunjukkan bahwa fungsi objektif yang digunakan dalam penelitian ini memiliki karakteristik yang relatif mudah dieksplorasi oleh SA. Ruang pencarian hanya terdiri atas dua variabel, sehingga kemungkinan SA kehilangan wilayah optimum akibat keterbatasan eksplorasi relatif kecil. Ketika wilayah optimum sudah cukup mudah dicapai, meningkatkan kemampuan eksplorasi tidak lagi menghasilkan perbaikan nilai objektif.

Nilai jarak Mahalanobis pada ketiga solusi juga berada pada kisaran 1.89 sampai 1.92, sehingga seluruh solusi tetap berada dalam wilayah *trust-region* yang diizinkan. Bahkan variasi ketiga menghasilkan nilai Mahalanobis paling rendah, yaitu 1.8935, yang menunjukkan bahwa solusi akhirnya justru sedikit lebih dekat terhadap distribusi data historis dibandingkan dua konfigurasi lainnya. Dengan demikian, perbedaan kecil daya optimum antar-konfigurasi bukan disebabkan oleh salah satu konfigurasi menghasilkan solusi yang berada jauh dari wilayah data historis.

Secara keseluruhan, hasil eksperimen menunjukkan bahwa T_0 terutama mempengaruhi tingkat eksplorasi pada fase awal, sedangkan α menentukan berapa lama kemampuan eksplorasi tersebut dipertahankan selama proses optimasi. Peningkatan T_0 dari 10 menjadi 50 meningkatkan *acceptance rate* dari 43.0% menjadi 58.0%, sedangkan perlambatan pendinginan dengan menaikkan α dari 0.995 menjadi 0.999 meningkatkan *acceptance rate* hingga 88.5%. Meskipun kedua strategi tersebut meningkatkan eksplorasi, tidak terdapat peningkatan terhadap solusi optimum karena seluruh konfigurasi telah mampu mencapai wilayah solusi yang sama.

Dengan demikian, perbedaan parameter SA pada penelitian ini lebih berpengaruh terhadap perilaku dan efisiensi proses pencarian daripada terhadap kualitas solusi akhir. Konfigurasi baseline variasi pertama dapat dipandang sebagai konfigurasi yang sudah memadai karena mampu mencapai daya sekitar 61.47 MW tanpa mempertahankan eksplorasi berlebihan sepanjang iterasi. Sementara itu, variasi kedua memberikan eksplorasi awal yang lebih besar dan variasi ketiga memberikan eksplorasi yang jauh lebih lama, tetapi keduanya tidak memberikan peningkatan solusi yang berarti.

IV.4 Optimasi dengan Metode Hybrid

Optimasi *hybrid* PSO-SA dilakukan dengan menggabungkan dua tahap pencarian secara berurutan. Pada tahap pertama, PSO digunakan sebagai *global search* untuk menemukan wilayah solusi yang memberikan nilai *net power* tinggi. Solusi terbaik yang diperoleh PSO (*gbest*) kemudian diteruskan sebagai titik awal bagi SA pada tahap kedua untuk melakukan pencarian lokal atau *refinement*. Tiga konfigurasi diuji dengan memvariasikan jumlah partikel pada fase PSO dan jumlah iterasi pada fase SA, sementara parameter lainnya dijaga tetap. Variasi pertama metode hybrid digunakan sebagai konfigurasi *baseline* dengan 30 partikel dan 800 iterasi SA, Variasi kedua meningkatkan jumlah partikel menjadi 80, sedangkan Variasi ketiga mempertahankan 30 partikel tetapi memperpanjang fase SA menjadi 2,000 iterasi.

Tabel IV. 6 Hasil optimasi hybrid untuk 3 variasi

Variasi	Jumlah partikel	Jumlah iterasi SA	Daya setelah PSO (MW)	Daya optimum	Mahalanobis
1	30	800	61.4704	61.4704	1.9211
2	80	800	61.4704	61.4704	1.9211
3	30	2000	61.4704	61.4704	1.9211

Hasil yang paling penting dari ketiga konfigurasi tersebut adalah bahwa seluruhnya menghasilkan nilai optimum yang identik, yaitu 61.4704 MW. Bahkan sebelum memasuki fase SA, ketiga konfigurasi telah menghasilkan nilai 61.4704 MW pada fase PSO. Setelah solusi tersebut diteruskan ke SA, tidak terdapat peningkatan nilai *net power* sama sekali.

Temuan tersebut memberikan gambaran yang sangat jelas mengenai perilaku hybrid pada permasalahan penelitian ini. PSO telah menemukan solusi yang sama dengan solusi akhir sebelum proses local search SA dimulai. Karena titik awal SA sudah berada pada titik optimum model, perpindahan lokal di sekitar titik tersebut tidak memberikan kandidat dengan nilai *net power* yang lebih tinggi. Dengan kata lain, pada permasalahan dua variabel yang digunakan dalam penelitian ini, fungsi objektif sudah dapat dieksplorasi dengan baik oleh PSO sehingga SA tidak memperoleh ruang untuk melakukan *refinement* lebih lanjut.

Perbedaan antara Variasi pertama metode hybrid dan Variasi kedua menunjukkan efek jumlah partikel pada fase *global search*. Ketika jumlah partikel dinaikkan dari 30 menjadi 80, nilai *net power* setelah fase PSO tetap sama, yaitu 61.4704 MW. Karena hasil yang diperoleh PSO dengan 30 partikel sudah mencapai titik yang sama, penambahan 50 partikel tidak memberikan peningkatan kualitas solusi.

Namun, biaya komputasinya meningkat cukup besar. Jumlah evaluasi fungsi meningkat dari 2,630 menjadi 5,680, atau sekitar 116%, sedangkan waktu komputasi meningkat dari sekitar 0.71 detik menjadi 1.42 detik. Jadi, lebih banyak partikel memang memberikan lebih banyak kandidat solusi pada fase eksplorasi, tetapi pada kasus ini informasi tambahan tersebut tidak menghasilkan solusi yang lebih baik.

Secara intuitif, hal ini terjadi karena ruang pencarian hybrid hanya terdiri atas dua fitur, yaitu $m_{in,turb}$ dan $P_{out,turb}$. Ruang dua dimensi ini relatif kecil, sehingga 30 partikel sudah memberikan cakupan yang cukup untuk menemukan wilayah optimum. Menambah jumlah partikel menjadi 80 menjadi seperti


menggunakan lebih banyak "tebakan" untuk mencari sesuatu yang sebenarnya sudah cukup mudah ditemukan.

Variasi pertama metode hybrid dan variasi ketiga digunakan untuk melihat apakah penambahan waktu *local search* dapat menghasilkan peningkatan setelah PSO menemukan *gbest*. Pada variasi ketiga, jumlah iterasi SA dinaikkan dari 800 menjadi 2,000. Meskipun fase SA diperpanjang sebanyak 1,200 iterasi tambahan, nilai *net power* tetap tidak berubah. Tidak adanya peningkatan tersebut menunjukkan bahwa SA tidak menemukan solusi yang lebih baik dari *gbest* PSO. Ini bukan berarti SA tidak berjalan, tetapi menunjukkan bahwa wilayah lokal di sekitar solusi yang diberikan PSO tidak mengandung solusi dengan nilai objektif yang lebih tinggi dalam batas pencarian yang digunakan.

Jumlah evaluasi meningkat dari 2,630 pada variasi pertama metode hybrid menjadi 3,830 pada variasi ketiga, atau sekitar 45.6%, sementara daya optimum tetap identik. Jadi, tambahan 1,200 iterasi SA tidak memberikan peningkatan kualitas solusi pada dataset dan model yang digunakan.

Analisis konvergensi dua fase

Grafik konvergensi hybrid memperlihatkan pemisahan yang jelas antara fase PSO dan fase SA. Pada fase PSO, nilai *best-so-far* bergerak menuju 61.4704 MW dan mencapai nilai tersebut sebelum batas 60 iterasi selesai. Setelah memasuki fase SA, kurva tetap berada pada nilai yang sama hingga akhir iterasi. Artinya, tidak terdapat lonjakan tambahan ketika transisi terjadi. Hal ini merupakan bukti visual dari hasil numerik bahwa SA tidak memberikan *gain* setelah PSO.



Gambar IV. 13 Konvergensi 2 fase PSO-SA

Hal ini menunjukkan bahwa seluruh konfigurasi hybrid tidak hanya memperoleh daya optimum yang identik, tetapi juga berakhir pada lokasi solusi yang sama dalam ruang fitur. Karena nilai tersebut masih berada di bawah batas *trust region* yang digunakan dalam penelitian, solusi akhir tetap berada pada wilayah yang memiliki dukungan statistik dari data historis.


Hasil hybrid PSO-SA menjadi menarik ketika dibandingkan dengan tujuan

awal penggabungan kedua algoritma. Secara teori, hibridisasi diharapkan menggabungkan kemampuan PSO dalam *global exploration* dengan kemampuan SA dalam *local refinement*. Namun, pada kasus penelitian ini, manfaat tambahan tersebut belum terlihat pada nilai objektif karena PSO sendiri telah mampu menemukan optimum.

Hal tersebut dapat dijelaskan oleh karakteristik permasalahan yang relatif sederhana, yaitu hanya memiliki dua variabel keputusan dan menggunakan model Polynomial Regression derajat 4 yang menghasilkan permukaan objektif yang relatif halus pada *trust region*. Dalam kondisi seperti ini, kemungkinan PSO berhenti pada optimum lokal yang berbeda dari optimum global relatif kecil. Akibatnya, SA tidak mendapatkan solusi yang perlu "diperbaiki".

IV.5 Solusi Optimasi Fungsi Objektif dari Ketiga algoritma

Untuk mengevaluasi konsistensi hasil optimasi, dilakukan perbandingan antara tiga pendekatan, yaitu Particle Swarm Optimization (PSO), Simulated Annealing (SA), dan hybrid PSO-SA. Masing-masing algoritma diuji dalam beberapa konfigurasi parameter untuk mengetahui apakah perubahan parameter algoritma menghasilkan perubahan terhadap solusi optimum yang diperoleh. Perbandingan dilakukan dengan menggunakan model *surrogate*, batas trust region, serta ruang pencarian yang sama sehingga perbedaan hasil dapat dikaitkan dengan karakteristik algoritma dan parameter optimasinya.




Gambar IV. 14 Perbandingan konvergensi untuk 3 metode

Pada pengujian awal, masing-masing metode dibandingkan menggunakan konfigurasi dasar. PSO menghasilkan nilai net power optimum sebesar 61.4704 MW, sedangkan SA menghasilkan 61.4703 MW. Hybrid PSO-SA juga menghasilkan 61.4704 MW. Ketiga nilai tersebut secara praktis hampir identik. Selisih antara hasil PSO dan SA hanya sebesar 0.0001 MW, sedangkan hasil

hybrid identik dengan PSO hingga empat angka desimal.

Tabel IV. 7 Perbandingan hasil optimasi untuk setiap algoritma

algoritma	Konfigurasi ke-	Solusi laju alir inlet turbin (T/h)	Solusi tekanan outlet turbin (bara)	Daya optimum (MW)	Mahalanobis
PSO	1	437.492011	0.148879	61.4704	1.9223
	2	437.820617	0.149067	61.4704	1.9249
	3	437.420906	0.149032	61.4704	1.8935
SA	1	437.620956	0.148968	61.4703	1.9211
	2	437.620945	0.148968	61.4701	1.9211
	3	437.598818	0.148925	61.4698	1.9253
Hybrid	1	437.621109	0.148968	61.4704	1.9211
	2	437.620666	0.148968	61.4704	1.9211
	3	437.621109	0.148968	61.4704	1.9211




Gambar IV. 15 Heatmap solusi dan hasil optimasi untuk ketiga metode optimasi

Kesamaan ini menunjukkan bahwa sejak konfigurasi awal, ketiga algoritma sudah mampu menemukan wilayah solusi yang sama. Dengan kata lain, tidak terdapat indikasi bahwa salah satu algoritma berhenti pada solusi lokal yang jauh lebih buruk dibandingkan algoritma lainnya. Hal ini juga menunjukkan bahwa karakteristik ruang solusi pada model yang digunakan relatif mudah dieksplorasi oleh ketiga pendekatan.

Temuan tersebut kemudian diperiksa dengan memperluas pengujian menjadi sembilan konfigurasi, yang terdiri atas tiga konfigurasi PSO, tiga konfigurasi SA, dan tiga konfigurasi hybrid PSO-SA. Hasil lengkap optimasi dapat

dirangkum sebagai berikut.



Gambar IV. 16 Peta 2D solusi optimasi dengan trust region jarak Mahalanobis

Berdasarkan tabel tersebut, seluruh konfigurasi PSO memberikan nilai optimum yang sama, yaitu 61.4704 MW. Hal ini menunjukkan bahwa perubahan parameter PSO yang diuji sebelumnya, baik jumlah partikel maupun bobot inersia, tidak mengubah lokasi solusi akhir. Variasi parameter tersebut hanya mempengaruhi perilaku pencarian dan jumlah iterasi yang diperlukan untuk mendekati solusi, sementara kualitas solusi akhirnya tetap sama.

Pada metode SA, terdapat variasi nilai optimum yang sedikit lebih besar dibandingkan PSO. Variasi pertama metode SA menghasilkan 61.4703 MW, variasi kedua menghasilkan 61.4701 MW, dan variasi ketiga menghasilkan 61.4698 MW. Meskipun terdapat perbedaan hingga 0.0005 MW, perbedaan tersebut sangat kecil dibandingkan skala daya pembangkitan, sehingga secara praktis ketiga konfigurasi tetap mencapai solusi yang sama, yaitu sekitar 61.47 MW. Variasi kecil tersebut lebih mencerminkan perbedaan lintasan pencarian akibat perubahan temperatur awal dan skema pendinginan daripada perbedaan lokasi optimum yang substansial.

Pada hybrid PSO-SA, ketiga konfigurasi kembali menghasilkan nilai 61.4704 MW. Hasil tersebut menunjukkan bahwa fase PSO sudah mampu

membawa proses pencarian menuju solusi optimum, sementara fase SA yang digunakan sebagai *local refinement* tidak menemukan solusi dengan nilai yang lebih tinggi. Dengan demikian, hybridisasi mempertahankan solusi yang telah diperoleh PSO tanpa menghasilkan perubahan terhadap nilai optimum.

Jika seluruh sembilan hasil tersebut dibandingkan secara bersamaan, nilai *net power* optimum hanya berada pada rentang:

$$61.4698 \leq P_{net,opt} \leq 61.4704 \text{ MW.}$$

Rentang tersebut memiliki selisih maksimum sebesar

$$\Delta P_{net} = 0.0006 \text{ MW} = 0.6 \text{ kW.}$$

Dibandingkan dengan nilai optimum sekitar 61.47 MW, selisih tersebut hanya sekitar

$$\frac{0,0006}{61.47} \times 100\% \approx 0.001\%.$$

Nilai yang sangat kecil ini menunjukkan bahwa solusi optimum sangat robust terhadap variasi algoritma dan parameter algoritma yang diuji. Dengan kata lain, perubahan mekanisme pencarian tidak menggeser solusi menuju wilayah lain yang memiliki nilai objektif berbeda secara signifikan.

Konsistensi hasil tersebut juga terlihat dari nilai jarak Mahalanobis. Seluruh solusi berada pada kisaran sekitar 1.89 sampai 1.92, sehingga tetap berada pada wilayah *trust region* yang ditetapkan. Artinya, kesamaan hasil bukan terjadi karena algoritma menghasilkan prediksi tinggi pada kombinasi parameter yang berada jauh dari distribusi data historis. Solusi yang ditemukan tetap berada pada wilayah kondisi operasi yang didukung oleh data.

Secara konseptual, hasil ini menunjukkan bahwa bentuk permukaan fungsi objektif pada ruang dua variabel relatif terstruktur dan tidak memiliki banyak optimum lokal yang dominan. Karena variabel yang dioptimasi hanya laju inlet turbin dan tekanan outlet turbin, algoritma relatif mudah mengeksplorasi seluruh ruang pencarian. Oleh sebab itu, keunggulan eksplorasi tambahan dari peningkatan jumlah partikel pada PSO maupun kemampuan menerima solusi yang lebih buruk pada SA tidak menghasilkan perbedaan solusi akhir yang berarti.

Temuan tersebut juga menjelaskan mengapa nilai optimum antara PSO, SA, dan hybrid hampir sama meskipun mekanisme pencariannya berbeda. Perbedaan utama ketiga metode lebih terlihat pada bagaimana solusi tersebut dicapai, misalnya kecepatan konvergensi, jumlah evaluasi fungsi, tingkat eksplorasi, dan biaya komputasi, bukan pada kualitas solusi akhirnya. PSO cenderung memperoleh solusi melalui pergerakan kolektif partikel menuju *gbest*, SA melalui pencarian lokal probabilistik, sedangkan hybrid menggunakan PSO untuk menemukan wilayah

optimum kemudian SA untuk melakukan pencarian lokal. Dalam kasus ini, ketiganya berakhir pada wilayah solusi yang sama.

Nilai *net power* hasil optimasi kemudian digunakan untuk menghitung efisiensi eksergi sistem. Karena produk sistem didefinisikan sebagai daya listrik netto, efisiensi eksergi dihitung dengan

$$\eta_{ex} = \frac{P_{net}}{\dot{E}_{in}} \times 100\%.$$

Dengan eksergi inlet yang digunakan sebesar $\dot{E}_{in} = 119.308$ MW, maka untuk hasil PSO sebesar 61.4704 MW.

$$\eta_{ex} = \frac{119.308}{61.6704} \times 100\% = 51,5224\%.$$

Jika dibandingkan dengan kondisi median dengan $P_{net,med} = 59.2651$, didapatkan efisiensi eksergi sebesar 49.67%. Daya mendapatkan kenaikan sebesar 2.2053 MW dan efisiensi eksergi naik sebesar 3.72% dibandingkan kondisi beban median.

BAB V

SIMPULAN DAN SARAN

V.1 Simpulan

Model *surrogate* dengan data operasional PLTP menghasilkan polinomial orde 4 dengan 2 fitur terpilih, yaitu laju inlet turbin dan tekanan outlet turbin. Model menghasilkan sebesar 0.9498 pada data *training* dan 0.9508 pada data *testing*, dengan MAE sebesar 0.3372 MW, RMSE sebesar 0.4286 MW, dan MAPE sebesar 0.57% pada data *testing*. Hasil ini menggambarkan bahwa model *surrogate* dibangun dengan kualitas yang sangat baik.

Model *surrogate* melalui tahap optimasi dengan tiga algoritma berbeda dengan masing-masing tiga konfigurasi untuk setiap metode optimasi. Kombinasi parameter operasi optimum dengan ketiga algoritma optimasi ini menghasilkan solusi laju inlet turbin sekitar 437.6 T/h dan tekanan outlet turbin sekitar 0.149 bara. Kombinasi ini menghasilkan daya keluaran bersih sekitar 61.47 MW.

Hasil dari pengujian variasi konfigurasi parameter algoritma PSO, SA, dan hybrid menunjukkan nilai daya keluaran bersih berada pada rentang 61.4698 hingga 61.4704 MW. Perbedaan hanya sekitar 0.0006 MW, sehingga perubahan parameter algoritma tidak mengakibatkan hasil yang berbeda secara signifikan. Hal ini menunjukkan, solusi yang diperoleh memiliki konsistensi dan robustness yang tinggi terhadap variasi metode maupun parameter optimasi.

Melalui perhitungan efisiensi eksergi dengan eksergi inlet ditetapkan sebesar 119.308 MW, kondisi median operasi memiliki nilai efisiensi sebesar 49.67%, sementara pada kondisi optimum setelah optimasi dengan daya listrik keluaran sebesar 61.4704 MW didapat efisiensi eksergi sebesar 51.52%. Hasil optimasi mampu meningkatkan daya listrik keluaran sebesar 2.21 MW atau 3.72% dibandingkan kondisi median operasi, serta peningkatan efisiensi sekitar 1.85%. Hasil di atas juga menunjukkan adanya potensi peningkatan performa berdasarkan pendekatan optimasi berbasis data operasional.

V.2 Saran

Penelitian selanjutnya dapat menggunakan lebih banyak parameter operasi sebagai variabel keputusan untuk melihat responsnya terhadap akurasi dan presisi dari model. Penambahan variabel dapat memberikan ruang optimasi yang lebih

representatif terhadap kondisi operasi pembangkit dan memungkinkan pengaruh interaksi antarparameter untuk dianalisis lebih lanjut.

Model ML lain dapat diaplikasikan untuk kasus ini untuk menentukan model terbaik yang dapat memodelkan sistem PLTP. Begitu pula dengan metode optimasi yang digunakan, untuk penelitian lebih lanjut dapat menggunakan algoritma lain sebagai perbandingan seperti Genetic Algorithm (GA).

Hasil solusi sebaiknya divalidasi dengan data operasional yang ada juga dengan menggunakan model termodinamika. Hal ini dilakukan untuk memastikan bahwa peningkatan daya bersih keluaran yang dihasilkan dari solusi optimasi sesuai dengan data operasi aktual.

Penelitian lanjutan dapat dikembangkan untuk multiobjective problems, seperti untuk memaksimalkan keuntungan yang didapatkan perusahaan dengan mengoptimasi parameter-parameter tertentu.

DAFTAR PUSTAKA

- Andersen, J. R., Imsland, L., & Pavlov, A. (2023). Data-driven derivative-free trust-region model-based method for resource allocation problems. *Computers & Chemical Engineering*, 176, 108282. <https://doi.org/10.1016/J.COMPCHEMENG.2023.108282>
- Aslam, S., Aung, P. P., Rafsanjani, A. S., & Majeed, A. P. P. A. (2025). Machine learning applications in energy systems: current trends, challenges, and research directions. In *Energy Informatics* (Vol. 8, Number 1). Springer Nature. <https://doi.org/10.1186/s42162-025-00524-6>
- Çetin, G., & Keçebaş, A. (2021). Optimization of thermodynamic performance with simulated annealing algoritma: A geothermal power plant. *Renewable Energy*, 172, 968–982. <https://doi.org/10.1016/j.renene.2021.03.101>
- Delahaye, D., Chaimatanan, S., & Mongeau, M. (2019). Simulated annealing: From basics to applications. In *International Series in Operations Research and Management Science* (Vol. 272, pp. 1–35). Springer New York LLC. https://doi.org/10.1007/978-3-319-91086-4_1
- Deng, W., Xu, J., & Zhao, H. (2019). An Improved Ant Colony Optimization algoritma Based on Hybrid Strategies for Scheduling Problem. *IEEE Access*, 7, 20281–20292. <https://doi.org/10.1109/ACCESS.2019.2897580>
- DiPippo, R. (2016). Exergy Analysis Applied to Geothermal Power Systems. In *Geothermal Power Plants* (pp. 291–318). Elsevier. <https://doi.org/10.1016/b978-0-08-100879-9.00010-0>
- Farnham, B., Tokyo, S., Boston, B., Sebastopol, F., & Beijing, T. (n.d.). *Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow Concepts, Tools, and Techniques to Build Intelligent Systems SECOND EDITION*.
- Gad, A. G. (2022). Particle Swarm Optimization algoritma and Its Applications: A Systematic Review. *Archives of Computational Methods in Engineering*, 29(5), 2531–2561. <https://doi.org/10.1007/s11831-021-09694-4>
- James, Gareth., Witten, Daniela., Hastie, Trevor., & Tibshirani, Robert. (2017). *An introduction to statistical learning : with applications in R*. Springer : Springer Science+Business Media.
- Javidrad, F., & Nazari, M. (2017). A new hybrid particle swarm and simulated annealing stochastic optimization method. *Applied Soft Computing*, 60, 634–654. <https://doi.org/10.1016/J.ASOC.2017.07.023>
- Lee, K. C. (2000). *Classification of geothermal resources by exergy*. Retrieved www.elsevier.com/locate/geothermics
- Mirjalili, S., Mirjalili, S. M., & Lewis, A. (2014). Grey Wolf Optimizer. *Advances in Engineering Software*, 69, 46–61. <https://doi.org/10.1016/j.advengsoft.2013.12.007>
- Nenny, I., & Saptadji, M. (n.d.). *TEKNIK PANASBUMI*.
- Nino-Ruiz, E. D. (2018). Implicit surrogate models for trust region based methods. *Journal of Computational Science*, 26, 264–274. <https://doi.org/10.1016/J.JOCS.2018.02.003>
- Pambudi, N. A. (2018). Geothermal power generation in Indonesia, a country within the ring of fire: Current status, future development and policy. In

- Renewable and Sustainable Energy Reviews* (Vol. 81, pp. 2893–2901). Elsevier Ltd. <https://doi.org/10.1016/j.rser.2017.06.096>
- Pambudi, N. A., & Ulfa, D. K. (2024). The geothermal energy landscape in Indonesia: A comprehensive 2023 update on power generation, policies, risks, phase and the role of education. In *Renewable and Sustainable Energy Reviews* (Vol. 189). Elsevier Ltd. <https://doi.org/10.1016/j.rser.2023.114008>
- Rashedi, E., Nezamabadi-pour, H., & Saryazdi, S. (2009). GSA: A Gravitational Search algoritma. *Information Sciences*, 179(13), 2232–2248. <https://doi.org/10.1016/j.ins.2009.03.004>
- Rashedi, E., Rashedi, E., & Nezamabadi-pour, H. (2018). A comprehensive survey on gravitational search algoritma. *Swarm and Evolutionary Computation*, 41, 141–158. <https://doi.org/10.1016/j.swevo.2018.02.018>
- Rudiyanto, B., Bahthiyar, M. A., Pambudi, N. A., Widjonarko, & Hijriawan, M. (2021). An update of second law analysis and optimization of a single-flash geothermal power plant in Dieng, Indonesia. *Geothermics*, 96. <https://doi.org/10.1016/j.geothermics.2021.102212>
- Shieh, H. L., Kuo, C. C., & Chiang, C. M. (2011). Modified particle swarm optimization algoritma with simulated annealing behavior and its numerical verification. *Applied Mathematics and Computation*, 218(8), 4365–4383. <https://doi.org/10.1016/J.AMC.2011.10.012>